Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Kandidat Bahasa Indonesia

Tugas Akhir

diajukan untuk memenuhi salah satu syarat memperoleh gelar sarjana
pada Program Studi Informatika
Direktorat Kampus Purwokerto
Universitas Telkom

2311102293
Rozhak



Program Studi Sarjana Informatika
Direktorat Kampus Purwokerto
Universitas Telkom
Purwokerto
2026

LEMBAR PENGESAHAN

Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Kandidat Bahasa Indonesia

Reliability Analysis of LLM-as-a-Judge under Prompt and Candidate Position Variations in Indonesian

2311102293
Rozhak

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagai syarat
memperoleh gelar pada Program Studi Sarjana Informatika
Direktorat Kampus Purwokerto
Universitas Telkom

Purwokerto, 21 Mei 2026
Menyetujui

Pembimbing I,	Pembimbing II,
Andi Prademon Yunus, S.T., M.Sc.Eng., Ph.D	Nisrina Hanifa Setiono, S.Kom., M.Cs
NIP: 23930008	NIP: 25010030
Penguji I,	Penguji II,
(Nama Lengkap Penguji 1 dan Gelar)	(Nama Lengkap Penguji 2 dan Gelar)
NIP: 12345	NIP: 12345

Ketua Program Studi Sarjana Informatika,

Aditya Dwi Putro W, S.Kom., M.Kom
NIP: 17930003

LEMBAR ORISINALITAS

Dengan ini saya, Rozhak, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Kandidat Bahasa Indonesia beserta dengan seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menanggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Purwokerto, 21 Mei 2026
Yang menyatakan

Materai 10.000

Rozhak
NIM: 2311102293

ABSTRAK

Abstrak ditulis dengan format font Time New Roman size 11 spasi 1 dalam bahasa Indonesia. Isinya merupakan uraian singkat tetapi lengkap mengenai permasalahan, tujuan, metode penelitian, hasil, dan kesimpulan. Tujuan penelitian disarikan dari tujuan penelitian pada pendahuluan, metode penelitian disarikan dari proses penelitian, dan hasil penelitian ditarik dari kesimpulan dengan nilai hasil secara kualitatif dan kuantitatif. Abstrak atau abstract terdiri atas satu alinea dan satu spasi maksimal 200 kata. Tidak boleh ada sitasi pada abstrak. Pada abstrak tidak menggunakan penamaan, simbol atau istilah yang teknis, misalnya minsup untuk menyatakan nilai support minimal.

Kata Kunci: merupakan kata-kata kunci yang menjelaskan isi tulisan, biasanya dapat diambil dari judul dan abstrak. Maksimal enam buah dan ditulis dengan huruf kecil. Contoh: abstrak, bahasa Indonesia, kualitatif, kuantitatif

ABSTRACT

The abstract should state briefly the general aspects of the subject and the main conclusions. The length of abstract should bo no more than 200 words and should be typed be with 11 pts. Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do euismod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Keywords: keyword should be chosen that they best describe the contents of the paper and should be typed in lower-case, except abbreviation. Keyword should be no more than 6 words.

KATA PENGANTAR

Kata pengantar laporan tugas akhir ini berisi ucapan syukur, penjelasan singkat tentang tujuan dan latar belakang penulisan, serta ucapan terima kasih kepada pihak-pihak yang telah membantu proses penyusunan tugas akhir.

1. Ucapan syukur kepada Tuhan Yang Maha Esa.
2. Ucapan terimakasih kepada Rektor Universitas Telkom.
3. Ucapan terimakasih kepada Direktur Universitas Telkom Direktorat Kampus Purwokerto.
4. Ucapan terimakasih kepada Ketua Program Studi.
5. Ucapan terimakasih kepada Dosen Pembimbing.
6. Ucapan terima kasih kepada individu maupun lembaga yang memberikan bantuan, bimbingan dan dukungan yang relevan.

Purwokerto, 21 Mei 2026

Rozhak

DAFTAR ISI

LEMBAR PENGESAHAN ii

LEMBAR ORISINALITAS iii

ABSTRAK iv

ABSTRACT v

KATA PENGANTAR vi

DAFTAR ISI vii

DAFTAR GAMBAR ix

DAFTAR TABEL x

DAFTAR LAMPIRAN xi

BAB I PENDAHULUAN 1

1.1. Latar Belakang 1

1.2. Rumusan Masalah 3

1.3. Tujuan Penelitian 4

1.4. Manfaat Penelitian 4

1.5. Batasan Masalah 4

1.6. Hipotesis Penelitian 5

1.7. Jadwal Penelitian 5

BAB II LANDASAN TEORI 7

2.1. Tinjauan Pustaka 7

2.2. Landasan Teori 7

2.2.1. Sub Topik 1 7

2.2.2. Sub Topik 2 7

2.2.3. Sub Topik Dst 7

BAB III METODE PENELITIAN 9

3.1. Subjek dan Objek Penelitian 9

3.2. Alat dan Bahan Penelitian 9
3.2.1. Alat Penelitian 9
3.2.2. Bahan Penelitian 9
3.2.3. Diagram Alir Penelitian 9

BAB IV HASIL DAN PEMBAHASAN 11
4.1. Hasil 11
4.2. Pembahasan 11
4.3. Implikasi Tugas Akhir (Khusus SI) 11

BAB V KESIMPULAN DAN SARAN 12
5.1. Kesimpulan 12
5.2. Saran 12

DAFTAR PUSTAKA 13

LAMPIRAN 15

DAFTAR GAMBAR

2.1 Contoh Logo Institusi 8

3.1 Contoh Diagram Alir Penelitian 10

DAFTAR TABEL

1.1 Jadwal penelitian tugas akhir. 6

DAFTAR LAMPIRAN

1
simulasi algoritma.10

Lampiran A: Daftar Pustaka dan Publikasi **15**

Lampiran B: Source Code Program **16**

Lampiran C: Panduan Penggunaan Aplikasi **17**

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perkembangan *large language model* (LLM) mendorong pemanfaatan model bahasa generatif pada berbagai tugas pemrosesan bahasa alami [1][2]. Penilaian kualitas respons yang dihasilkan LLM umumnya memerlukan preferensi manusia (*human preference*) sebagai acuan, tetapi evaluasi manual membutuhkan biaya dan waktu yang besar ketika jumlah data pengujian meningkat [1][3]. Kebutuhan tersebut melahirkan paradigma *LLM-as-a-Judge*, yaitu penggunaan LLM sebagai penilai otomatis, salah satunya melalui perbandingan berpasangan (*pairwise comparison*) untuk memilih respons yang lebih baik di antara dua kandidat [1][4]. Pada pengujian berbahasa Inggris seperti MT-Bench dan Chatbot Arena, model penilai seperti GPT-4 dilaporkan mampu mencapai kesepakatan di atas 80% terhadap preferensi manusia pada pasangan keputusan non-seri [1].

Meskipun demikian, penerapan *LLM-as-a-Judge* menghadapi masalah reliabilitas karena keputusan model belum tentu konsisten ketika urutan posisi kandidat ditukar (*position bias*) [1][5] maupun ketika kalimat instruksi penilaian diubah (*prompt sensitivity*) [6][7]. Hal ini terjadi karena model penilai peka terhadap urutan penempatan kandidat di dalam konteks masukan, terutama saat selisih kualitas antarkandidat berdekatan [4][5], serta terhadap cara perumusan instruksi dan kriteria penilaian di dalam *prompt* [6][7]. Ketidakstabilan tersebut terlihat pada pengujian MT-Bench dengan *prompt* bawaan, ketika pertukaran urutan kandidat dari A–B menjadi B–A pada pasangan respons yang setara hanya menyisakan konsistensi keputusan sebesar 23,8%–65,0% [1], serta pada perbandingan berpasangan terbuka yang mengalami pembalikan putusan (*preference flip*) sebesar 48,4% saat urutan respons dibalik [8]. Perubahan redaksi instruksi yang setara secara semantik (*semantically equivalent*) juga menurunkan konsistensi putusan model melampaui variasi dekoding internal (*decoding noise*) [7], sedangkan perbedaan *template prompt* dapat menggeser tingkat kesepakatan dengan manusia serta membalik arah kecenderungan posisi dari kandidat pertama ke kandidat kedua [6]. Selain itu, pengukuran kesepakatan yang hanya mengandalkan persentase kecocokan mentah (*exact match*) melampaui

nilai Cohen's kappa sebesar 33,8 hingga 41,3 poin persentase pada MT-Bench karena belum memperhitungkan peluang acak [9], serta dapat memberikan gambaran performa yang menyesatkan ketika distribusi putusan timpang [10]. Apabila reliabilitas penilai tidak diukur secara terkontrol, keputusan pemilihan kandidat dapat berubah akibat pergeseran urutan penyajian [5][9] atau formulasi *prompt* [6][7], serta menghasilkan pemeringkatan kualitas model yang bias pada sistem evaluasi yang lebih luas ketika penilaian dari *judge* yang kurang andal diagregasikan secara langsung [11].

Permasalahan reliabilitas tersebut semakin relevan untuk dikaji pada Bahasa Indonesia. Dari 650 publikasi *LLM-as-a-Judge* di repositori ACL Anthology, hanya 33 penelitian (5,1%) yang mengkaji konteks multibahasa atau bahasa bersumber daya rendah, dengan validasi keandalan penilai yang kerap dilewatkan pada bahasa sasaran atau hanya bertumpu pada satu model *judge* [12]. Pengujian pada data paralel lintas 25 bahasa juga menunjukkan bahwa konsistensi penilaian model lintas bahasa masih rendah dengan rata-rata Fleiss' kappa sekitar 0,3 [13]. Untuk Bahasa Indonesia, telah tersedia dataset preferensi berpasangan IndoPref yang disusun dari penutur asli dan memuat 522 *prompt* serta 4.099 pasangan preferensi lintas 10 domain [14]. Namun, evaluasi pada dataset IndoPref menunjukkan bahwa akurasi *judge* tertinggi baru mencapai 74,34% (pada Gemini 2.5 Pro), dan penerjemahan *prompt* instruksi evaluasi dari bahasa Inggris ke Bahasa Indonesia dapat menurunkan akurasi model hingga 6,39 poin persentase (dari 69,84% menjadi 63,45% pada GPT-4.1) [14].

Beberapa pendekatan dapat digunakan untuk mengevaluasi dan menangani masalah ketidakstabilan *LLM-as-a-Judge* tersebut, antara lain pengujian kecocokan satu arah terhadap label referensi manusia tanpa menguji pembalikan urutan kandidat [3][14], mitigasi dua urutan yang menetapkan keputusan tidak konsisten (*inconsistent*) antara A–B dan B–A sebagai hasil seri (*tie*) [1][4], penggabungan suara dari beberapa model penilai (*ensemble judge*) [13], serta evaluasi reliabilitas terkontrol yang menguji pertukaran posisi kandidat [5][8] dan variasi formulasi *prompt* [6][7]. Sejauh ini, penelitian yang menguji *position bias* [1][5], sensitivitas formulasi *prompt* [6][7], serta koreksi metrik kesepakatan terhadap peluang [9][10] umumnya dilakukan pada korpus berbahasa Inggris, sedangkan penelitian pada dataset IndoPref [14] baru mengevaluasi akurasi satu arah tanpa mengisolasi pengaruh posisi kandidat dan variasi formulasi *prompt* berbahasa Indonesia yang setara secara semantik. Dengan demikian, studi khusus Bahasa Indonesia yang menggunakan *human preference* sebagai acuan dan eksperimen terkontrol yang memisahkan efek posisi kandidat serta formulasi *prompt* masih terbatas. Penelitian ini memilih pendekatan evaluasi empiris terkontrol dengan prinsip satu faktor berubah dalam satu waktu (*one factor at a time*),

karena pengujian satu arah tidak dapat mendeteksi pembalikan putusan, penetapan *tie* menyembunyikan proporsi *flip rate* pada pasangan kandidat, dan penggunaan *ensemble* membutuhkan inferensi dari beberapa model sekaligus tanpa mengisolasi sumber inkonsistensi pada model tunggal.

Penelitian ini mengusulkan evaluasi reliabilitas model sumber terbuka `Qwen/Qwen3-4B-Instruct-2507` sebagai instrumen *judge* tunggal yang dikontrol tetap pada 519 sampel terstratifikasi lintas 10 domain dari dataset IndoPref [14], sehingga variasi keputusan yang terukur tidak terbaur dengan perbedaan arsitektur antarmodel. Pengujian dijalankan pada enam kondisi kombinasi dari dua urutan posisi kandidat (kondisi A–B dan B–A) serta tiga formulasi *prompt* berbahasa Indonesia yang setara secara semantik, yaitu *prompt baseline* perbandingan holistik (P1), *prompt* multi-kriteria mencakup akurasi, relevansi, dan kejelasan (P2), serta *prompt* mitigasi bias (P3), dengan total 3.114 inferensi. Hasil inferensi tersebut dianalisis secara terkontrol melalui perbandingan antarkondisi posisi pada *prompt* yang sama dan antarformulasi *prompt* pada urutan posisi yang sama. Dibandingkan evaluasi satu arah yang hanya melaporkan akurasi mentah pada satu urutan dan satu *prompt*, pendekatan ini memungkinkan pengukuran kesepakatan terhadap preferensi manusia menggunakan metrik *accuracy* dan Cohen's kappa [9][10], sekaligus memisahkan besaran ketidakkonsistenan akibat posisi kandidat melalui *position consistency*, *preference flip rate*, dan *first-position preference rate* [5][9] serta akibat variasi formulasi *prompt* melalui *prompt consistency* dan *prompt flip rate* yang diadaptasi dari pengujian sensitivitas *prompt* [6][7]. Berdasarkan latar belakang dan permasalahan tersebut, penelitian ini bertujuan untuk mengukur dan menganalisis tingkat konsistensi keputusan `Qwen/Qwen3-4B-Instruct-2507` sebagai *LLM-as-a-Judge* terhadap *human preference* pada respons Bahasa Indonesia dalam dataset IndoPref, serta menganalisis pengaruh perubahan posisi kandidat dan variasi formulasi *prompt* terhadap konsistensi keputusannya.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Seberapa konsisten keputusan LLM-as-a-Judge dengan *human preference* pada respons Bahasa Indonesia?
2. Bagaimana perubahan posisi kandidat (A–B dan B–A) memengaruhi konsistensi keputusan LLM-as-a-Judge?

3. Bagaimana variasi formulasi *prompt* memengaruhi konsistensi keputusan LLM-as-a-Judge?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diidentifikasi, tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Mengukur tingkat konsistensi keputusan *LLM-as-a-Judge* terhadap *human preference* pada respons Bahasa Indonesia menggunakan metrik *accuracy* dan Cohen's kappa.

2. Menganalisis pengaruh perubahan posisi kandidat (A–B dan B–A) terhadap konsistensi keputusan *LLM-as-a-Judge* menggunakan metrik *position consistency*, *preference flip rate*, dan *first-position preference rate*.

3. Menganalisis pengaruh variasi formulasi *prompt* yang setara secara semantik terhadap konsistensi keputusan *LLM-as-a-Judge* menggunakan metrik *prompt consistency* dan *prompt flip rate*.

1.4. Manfaat Penelitian

Apabila permasalahan dalam penelitian ini dapat diselesaikan, manfaat yang diharapkan bagi pihak terkait adalah sebagai berikut:

1. **Bagi Akademisi:** Menjadi rujukan empiris dan protokol pengujian yang dapat direplikasi mengenai reliabilitas *LLM-as-a-Judge* pada evaluasi respons Bahasa Indonesia.

2. **Bagi Praktisi dan Pengembang:** Menjadi bahan pertimbangan dalam memilih formulasi *prompt* dan mengantisipasi bias posisi kandidat saat menggunakan LLM sebagai penilai otomatis.

1.5. Batasan Masalah

Untuk memperjelas ruang lingkup dan kondisi berlakunya hasil penelitian, batasan masalah dalam penelitian ini ditetapkan sebagai berikut:

1. Model *judge* yang diuji dibatasi pada satu model sumber terbuka, yaitu `Qwen/Qwen3-4B-Instruct-2507` dengan kuantisasi 4-bit pada lingkungan

Google Colab satu GPU tanpa *training* atau *fine-tuning*, sehingga temuan penelitian berlaku spesifik pada model dan konfigurasi tersebut.

2. Data pengujian menggunakan 519 sampel terstratifikasi lintas 10 domain dari dataset IndoPref dengan memanfaatkan label *reference human preference* yang tersedia tanpa perekrutan anotator baru.

3. Pengujian posisi kandidat dilakukan pada perbandingan berpasangan dua urutan, yaitu kondisi A–B (kandidat A ditampilkan pertama dan kandidat B kedua) serta kondisi B–A (kandidat B ditampilkan pertama dan kandidat A kedua).

4. Variasi *prompt* menggunakan tiga formulasi berbahasa Indonesia yang setara secara semantik, yaitu *baseline* holistik (P1), multi-kriteria (P2), dan mitigasi bias (P3).

5. Keluaran eksperimen utama dibatasi pada pilihan biner (`A` atau `B`) tanpa penalaran *Chain-of-Thought*.

1.6. Hipotesis Penelitian

Berdasarkan pengujian terkontrol terhadap variasi posisi kandidat dan formulasi *prompt*, penelitian ini mengajukan hipotesis sebagai berikut:

1. Perubahan posisi kandidat dapat menyebabkan perubahan keputusan LLM-as-a-Judge dan menurunkan konsistensi keputusan terhadap *human preference*.

2. Variasi formulasi *prompt* yang *semantically equivalent* dapat menyebabkan perubahan keputusan LLM-as-a-Judge dan memengaruhi konsistensinya terhadap *human preference*.

1.7. Jadwal Penelitian

Jadwal pelaksanaan penelitian ini disusun selama enam bulan sebagaimana ditunjukkan pada Tabel 1.1.

Tabel 1.1: Jadwal penelitian tugas akhir.

No	Kegiatan	Bulan ke-																					
		1				2				3				4				5				6			
1	Studi Literatur																								
2	Penyiapan Data IndoPref dan Sampling																								
3	Perancangan Prompt dan Konfigurasi Uji																								
4	Pelaksanaan Eksperimen Inferensi																								
5	Analisis Reliabilitas dan Evaluasi Statistik																								
6	Penulisan Laporan Tugas Akhir																								

Tabel 1.1 menyajikan tahapan pengerjaan Tugas Akhir mulai dari studi literatur, penyiapan data, perancangan dan pelaksanaan eksperimen, analisis hasil, hingga penulisan laporan.

BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Bagian kajian pustaka diawali dengan ringkasan hasil kajian pustaka (paper atau jurnal) terkait research question atau problem statement yang diajukan pada Bab Pendahuluan.

Contoh pustaka prosiding [**?**], jurnal [**?**][**?**] dan buku [**?**]. Atau dapat juga menggunakan dua pustaka atau lebih dalam [**? ?**].

2.2. Landasan Teori

Teori pendukung dapat berasal dari textbook, paper/jurnal, tesis, dan TA lain dengan memperhatikan penggunaan teknik acuan sebagai bentuk kejujuran akademik.

2.2.1. Sub Topik 1

Menurut paper Kentang [**?**], persamaan SWE adalah sebagai berikut:

$$a = b + U_{i+1}^{n+1} \tag{2.1}$$

Persamaan (2.1) adalah contoh persamaan.

2.2.2. Sub Topik 2

$$\int_0^1 \frac{f(x)}{g(x)} \, \mathrm{dx} = \sin x \tag{2.2}$$

$$\alpha \times \beta = \gamma^{3\alpha} \tag{2.3}$$

2.2.3. Sub Topik Dst

Berikut adalah contoh gambar: Lihat *pada* Gambar 2.1.



Gambar 2.1: Contoh Logo Institusi

BAB III

METODE PENELITIAN

Metode penelitian berisikan alur pembuatan model, dapat berupa diagram block proses atau flowchart, beserta penjelasannya.

3.1. Subjek dan Objek Penelitian

Berisi penjelasan terkait subjek atau objek yang akan diteliti. Rancangan sistem dapat berisikan rencana kebutuhan data (pengumpulan dan pre-processing data), serta skenario pengujian yang akan dilakukan.

3.2. Alat dan Bahan Penelitian

3.2.1. Alat Penelitian

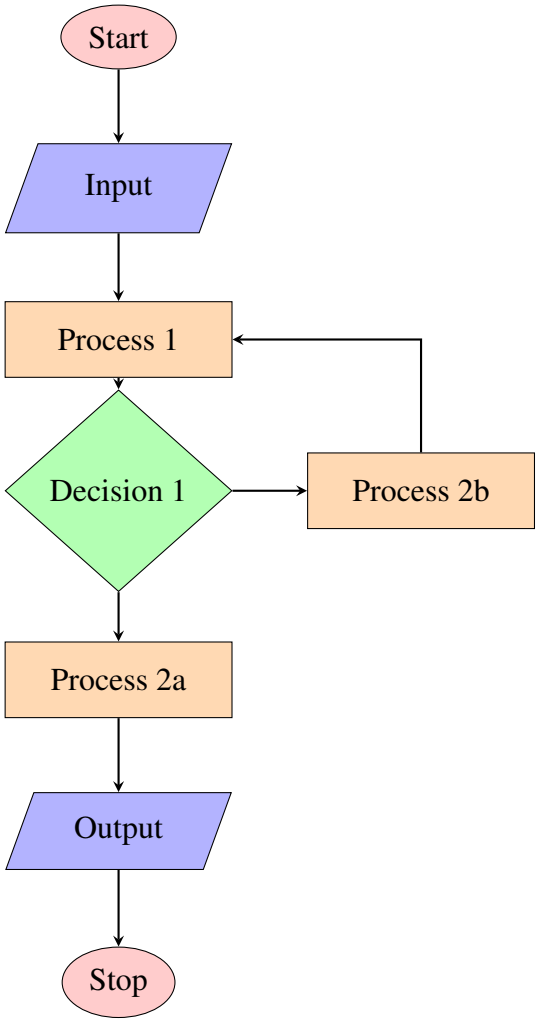
Sebutkan alat-alat (hardware/software) yang akan digunakan selama penelitian.

3.2.2. Bahan Penelitian

Sebutkan bahan-bahan pendukung, pustaka utama, atau dataset yang digunakan.

3.2.3. Diagram Alir Penelitian

Atau dalam bentuk algoritma seperti contoh pada Algoritma 1 berikut ini:



Gambar 3.1: Contoh Diagram Alir Penelitian

Algorithm 1 Prosedur simulasi algoritma.

procedure FVDM($T final, \Delta t$)
    Start
    For $n = 1 : N$ **do** ▷ Pemberian nilai awal
        Input nilai $x[n]$
    EndFor
    time=0
    while $time < T final$ **do**
        $time = time + \Delta t$
        If($S(n) \leq 0m$) **then return End If**.
            OUTPUT Cetak hasil data.
    end while
    End
end procedure

BAB IV

HASIL DAN PEMBAHASAN

4.1. Hasil

Uraikan secara sistematis hasil penelitian atau pengujian yang telah dilakukan.

4.2. Pembahasan

Berikan analisis dan interpretasi mendalam terhadap hasil yang telah diperoleh, serta bandingkan dengan hipotesis atau teori yang ada.

4.3. Implikasi Tugas Akhir (Khusus SI)

(Khusus untuk mahasiswa Prodi S1 Sistem Informasi) Jelaskan implikasi dari hasil tugas akhir terhadap proses bisnis atau sistem yang berjalan.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berisi poin-poin kesimpulan yang menjawab rumusan masalah secara langsung.

5.2. Saran

Berisi masukan untuk pengembangan atau perbaikan penelitian selanjutnya berdasarkan keterbatasan penelitian ini.

DAFTAR PUSTAKA

[1] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," Dec. 2023.

[2] J. Gu, X. Jiang, Z. Shi, H. Tan, X. Zhai, C. Xu, W. Li, Y. Shen, S. Ma, H. Liu, S. Wang, K. Zhang, Y. Wang, W. Gao, L. Ni, and J. Guo, "A Survey on LLM-as-a-Judge," Oct. 2025.

[3] A. Bavaresco, R. Bernardi, L. Bertolazzi, D. Elliott, R. Fernández, A. Gatt, E. Ghaleb, M. Giulianelli, M. Hanna, A. Koller, A. F. T. Martins, P. Mondorf, V. Neplenbroek, S. Pezzelle, B. Plank, D. Schlangen, A. Suglia, A. K. Surikuchi, E. Takmaz, and A. Testoni, "LLMs instead of Human Judges? A Large Scale Empirical Study across 20 NLP Evaluation Tasks," June 2025.

[4] H. Li, Q. Dong, J. Chen, H. Su, Y. Zhou, Q. Ai, Z. Ye, and Y. Liu, "LLMs-as-Judges: A Comprehensive Survey on LLM-based Evaluation Methods," Dec. 2024.

[5] L. Shi, C. Ma, W. Liang, X. Diao, W. Ma, and S. Vosoughi, "Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge," in *Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics*, pp. 292–314, Association for Computational Linguistics, Dec. 2025.

[6] H. Wei, S. He, T. Xia, F. Liu, A. Wong, J. Lin, and M. Han, "Systematic Evaluation of LLM-as-a-Judge in LLM Alignment Tasks: Explainable Metrics and Diverse Prompt Templates," Mar. 2025.

[7] R. R. Bellibatlu, E. Raff, and W. Zhang, "JudgeSense: A Benchmark for Prompt Sensitivity in LLM-as-a-Judge Systems," Sept. 2026.

[8] C. Anghel, A. A. Anghel, E. Pecheanu, A. Cocu, A. Istrate, and C. A. Andrei, "Diagnosing Bias and Instability in LLM Evaluation: A Scalable Pairwise Meta-Evaluator," *Information*, vol. 16, p. 652, July 2025.

[9] J. D. Norman, M. U. Rivera, and D. A. Hughes, “Reliability without Validity: A Systematic, Large-Scale Evaluation of LLM-as-a-Judge Models Across Agreement, Consistency, and Bias,” June 2026.

[10] D. Rao and C. Callison-Burch, “Agreement Metrics for LLM-as-Judge Evaluation: What to Report and Why,” July 2026.

[11] M. Xu, X. Tan, J. Wu, and D. Zhou, “A Judge-Aware Ranking Framework for Evaluating Large Language Models without Ground Truth,” June 2026.

[12] A. S. Doğruöz, X. Liao, V. Blaschke, J. Prange, S. Li, and D. I. Adelani, “Challenges and Recommendations for LLM-as-a-Judge in Multilingual Settings and for Low-Resource Languages,” Sept. 2026.

[13] X. Fu and W. Liu, “How Reliable is Multilingual LLM-as-a-Judge?,” May 2025.

[14] V. R. Wiyono, D. Anugraha, A. Purwarianti, and G. I. Winata, “IndoPref: A Multi-Domain Pairwise Preference Dataset for Indonesian,” Nov. 2025.

Lampiran A: Daftar Pustaka dan Publikasi

Lampiran B: Source Code Program

Lampiran C: Panduan Penggunaan Aplikasi