Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Jawaban dalam Bahasa Indonesia

Tugas Akhir

diajukan untuk memenuhi salah satu syarat memperoleh gelar sarjana
pada Program Studi Informatika
Direktorat Kampus Purwokerto
Universitas Telkom

2311102293
Rozhak



Program Studi Sarjana Informatika
Direktorat Kampus Purwokerto
Universitas Telkom
Purwokerto
2026

LEMBAR PENGESAHAN

Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Jawaban dalam Bahasa Indonesia

Reliability Analysis of LLM-as-a-Judge under Prompt and Answer Position Variations in Indonesian

2311102293
Rozhak

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagai syarat
memperoleh gelar pada Program Studi Sarjana Informatika
Direktorat Kampus Purwokerto
Universitas Telkom

Purwokerto, 11 Mei 2026
Menyetujui

Pembimbing I,	Pembimbing II,
Andi Prademon Yunus, S.T., M.Sc.Eng., Ph.D	Nisrina Hanifa Setiono, S.Kom., M.Cs
NIP: 23930008	NIP: 25010030
Penguji I,	Penguji II,
(Nama Lengkap Penguji 1 dan Gelar)	(Nama Lengkap Penguji 2 dan Gelar)
NIP: 12345	NIP: 12345

Ketua Program Studi Sarjana Informatika,

Aditya Dwi Putro W, S.Kom., M.Kom
NIP: 17930003

LEMBAR ORISINALITAS

Dengan ini saya, Rozhak, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Jawaban dalam Bahasa Indonesia beserta dengan seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menanggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Purwokerto, 11 Mei 2026
Yang menyatakan

Materai 10.000

Rozhak
NIM: 2311102293

ABSTRAK

Abstrak ditulis dengan format font Time New Roman size 11 spasi 1 dalam bahasa Indonesia. Isinya merupakan uraian singkat tetapi lengkap mengenai permasalahan, tujuan, metode penelitian, hasil, dan kesimpulan. Tujuan penelitian disarikan dari tujuan penelitian pada pendahuluan, metode penelitian disarikan dari proses penelitian, dan hasil penelitian ditarik dari kesimpulan dengan nilai hasil secara kualitatif dan kuantitatif. Abstrak atau abstract terdiri atas satu alinea dan satu spasi maksimal 200 kata. Tidak boleh ada sitasi pada abstrak. Pada abstrak tidak menggunakan penamaan, simbol atau istilah yang teknis, misalnya minsup untuk menyatakan nilai support minimal.

Kata Kunci: merupakan kata-kata kunci yang menjelaskan isi tulisan, biasanya dapat diambil dari judul dan abstrak. Maksimal enam buah dan ditulis dengan huruf kecil. Contoh: abstrak, bahasa Indonesia, kualitatif, kuantitatif

ABSTRACT

The abstract should state briefly the general aspects of the subject and the main conclusions. The length of abstract should bo no more than 200 words and should be typed be with 11 pts. Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do euismod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Keywords: keyword should be chosen that they best describe the contents of the paper and should be typed in lower-case, except abbreviation. Keyword should be no more than 6 words.

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa karena atas rahmat dan karunia-Nya, Laporan Tugas Akhir yang berjudul "Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Jawaban dalam Bahasa Indonesia" dapat diselesaikan. Laporan ini disusun untuk memenuhi salah satu syarat memperoleh gelar sarjana pada Program Studi Sarjana Informatika, Direktorat Kampus Purwokerto, Universitas Telkom. Penulisan Tugas Akhir ini bertujuan untuk menganalisis konsistensi keputusan *LLM-as-a-Judge* terhadap variasi *prompt* dan urutan posisi jawaban dalam Bahasa Indonesia.

Penyusunan Tugas Akhir ini tidak terlepas dari bimbingan, bantuan, dan dukungan berbagai pihak. Oleh karena itu, penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr. Suyanto, S.T., M.Sc., selaku Rektor Universitas Telkom.
2. Bapak Prof. Dr. Z.K. Abdurahman Baizal, S.Si., M.Kom., selaku Direktur Universitas Telkom Direktorat Kampus Purwokerto.
3. Bapak Aditya Dwi Putro W., S.Kom., M.Kom., selaku Ketua Program Studi Sarjana Informatika Universitas Telkom Direktorat Kampus Purwokerto.
4. Bapak Andi Prademon Yunus, S.T., M.Sc.Eng., Ph.D., selaku Dosen Pembimbing I yang telah memberikan bimbingan dan arahan selama penyusunan Tugas Akhir ini.
5. Ibu Nisrina Hanifa Setiono, S.Kom., M.Cs., selaku Dosen Pembimbing II yang telah memberikan bimbingan dan masukan selama penyusunan Tugas Akhir ini.
6. Kedua orang tua dan keluarga, Bapak dan Ibu dosen, rekan-rekan mahasiswa, serta semua pihak yang telah memberikan doa, bantuan, dan dukungan selama penyusunan Tugas Akhir ini.

Penulis menyadari bahwa laporan ini masih memiliki kekurangan, sehingga kritik dan saran yang membangun tetap penulis harapkan. Semoga Laporan Tugas Akhir ini dapat bermanfaat bagi pembaca.

Purwokerto, 11 Mei 2026

Rozhak

DAFTAR ISI

LEMBAR PENGESAHAN ii

LEMBAR ORISINALITAS iii

ABSTRAK iv

ABSTRACT v

KATA PENGANTAR vi

DAFTAR ISI vii

DAFTAR GAMBAR ix

DAFTAR TABEL x

DAFTAR LAMPIRAN xi

BAB I PENDAHULUAN 1

1.1. Latar Belakang 1
1.2. Rumusan Masalah 3
1.3. Tujuan Penelitian 4
1.4. Manfaat Penelitian 4
1.5. Batasan Masalah 4
1.6. Hipotesis Penelitian 5
1.7. Jadwal Penelitian 5

BAB II LANDASAN TEORI 7

2.1. Tinjauan Pustaka 7
2.2. Landasan Teori 14
2.2.1. Large Language Models 14
2.2.2. LLM-as-a-Judge 15
2.2.3. Reliabilitas LLM Judge 15
2.2.4. Position Bias 16
2.2.5. Prompt Sensitivity 17
2.2.6. Evaluasi LLM Bahasa Indonesia 18

2.2.7. Sintesis dan Research Gap 19

BAB III METODE PENELITIAN 20

3.1. Subjek dan Objek Penelitian 20
3.2. Alat dan Bahan Penelitian 20
3.2.1. Alat Penelitian 21
3.2.2. Bahan Penelitian 25
3.3. Diagram Alir Penelitian 27

BAB IV HASIL DAN PEMBAHASAN 32

4.1. Hasil 32
4.2. Pembahasan 32

BAB V KESIMPULAN DAN SARAN 33

5.1. Kesimpulan 33
5.2. Saran 33

DAFTAR PUSTAKA 34

LAMPIRAN 37

DAFTAR GAMBAR

3.1 Diagram alir penelitian. 27

DAFTAR TABEL

1.1 Jadwal penelitian tugas akhir. 6

2.1 Ringkasan penelitian terdahulu. 7

3.1 Spesifikasi perangkat keras dan perangkat lunak penelitian. 22
3.2 Variabel bebas, variabel terikat, dan variabel kontrol penelitian. . . . 24
3.3 Distribusi bahan data pengujian IndoPref pada sepuluh domain topik. 26
3.4 Rancangan *system prompt* dan variasi *user prompt* evaluasi. 29
3.5 Skema penempatan posisi jawaban pada urutan A–B dan B–A. . . . 30

DAFTAR LAMPIRAN

Lampiran A: Daftar Pustaka dan Publikasi **37**

Lampiran B: Source Code Program **38**

Lampiran C: Panduan Penggunaan Aplikasi **39**

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perkembangan *large language model* (LLM) mendorong pemanfaatan model bahasa generatif pada berbagai tugas pemrosesan bahasa alami [1][2]. Penilaian kualitas respons yang dihasilkan LLM umumnya memerlukan preferensi manusia (*human preference*) sebagai acuan, tetapi evaluasi manual membutuhkan biaya dan waktu yang besar ketika jumlah data pengujian meningkat [1][3]. Kondisi tersebut mendorong penggunaan metode *LLM-as-a-Judge*, yaitu pemanfaatan LLM sebagai penilai otomatis, salah satunya melalui perbandingan berpasangan (*pairwise comparison*) untuk memilih jawaban yang lebih baik di antara dua respons model [1][4]. Pada pengujian berbahasa Inggris seperti MT-Bench dan Chatbot Arena, model penilai seperti GPT-4 dilaporkan mampu mencapai kesepakatan di atas 80% terhadap preferensi manusia pada pasangan penilaian yang tidak berakhir seri (*non-tie*) [1].

Meskipun demikian, penggunaan *LLM-as-a-Judge* masih memiliki masalah reliabilitas karena keputusan model belum tentu konsisten ketika urutan posisi jawaban ditukar (*position bias*) [1][5] maupun ketika kalimat instruksi penilaian diubah (*prompt sensitivity*) [6][7]. Masalah ini terjadi karena model penilai peka terhadap urutan penempatan jawaban di dalam *prompt*, terutama ketika kualitas kedua respons hampir setara [4][5], serta peka terhadap cara penyusunan kalimat instruksi dan kriteria penilaian [6][7]. Pada pengujian MT-Bench menggunakan *prompt* standar (*default*), penukaran posisi jawaban dari urutan A–B menjadi B–A pada pasangan respons yang setara membuat tingkat konsistensi keputusan model hanya berkisar antara 23,8% hingga 65,0% [1]. Ketidakstabilan serupa ditemukan pada pengujian pertanyaan terbuka (*open-ended*) yang mengalami perubahan keputusan (*preference flip*) sebesar 48,4% saat posisi jawaban dibalik [8]. Selain itu, perubahan susunan kalimat instruksi yang bermakna sama (*semantically equivalent*) terbukti menurunkan konsistensi keputusan model lebih besar daripada pengaruh pengulangan inferensi (*decoding noise*) [7], sedangkan perbedaan *template prompt* dapat menggeser tingkat kesepakatan dengan manusia sekaligus mengubah kecenderungan model dari memilih jawaban pertama menjadi jawaban kedua [6]. Di sisi lain, pengukuran kese-

pakatan yang hanya mengandalkan persentase kecocokan langsung (*exact match*) menghasilkan selisih 33,8 hingga 41,3 poin persentase lebih tinggi dibandingkan nilai Cohen's kappa pada MT-Bench karena belum memperhitungkan peluang kebetulan [9], sehingga dapat memberikan gambaran performa yang kurang akurat ketika distribusi keputusan model timpang [10]. Apabila reliabilitas penilai tidak diuji terhadap perubahan posisi jawaban maupun variasi *prompt*, hasil penilaian model dapat berubah hanya karena posisi jawaban ditukar [5][9] atau kalimat *prompt* diubah [6][7]. Pada sistem evaluasi yang lebih luas, penggabungan hasil penilaian dari *judge* yang kurang konsisten juga dapat menghasilkan peringkat kualitas antarmodel yang bias [11].

Permasalahan reliabilitas tersebut penting untuk dikaji pada Bahasa Indonesia. Dari 650 publikasi *LLM-as-a-Judge* di repositori ACL Anthology, hanya 33 penelitian (5,1%) yang membahas konteks multibahasa atau bahasa dengan keterbatasan data (*low-resource*), dan sebagian besar di antaranya belum memvalidasi keandalan penilai pada bahasa yang diuji atau hanya mengandalkan satu model *judge* [12]. Pengujian pada data paralel di 25 bahasa juga menunjukkan bahwa konsistensi penilaian model antarbahasa masih rendah, dengan rata-rata Fleiss' kappa sekitar 0,3 [13]. Untuk Bahasa Indonesia, telah tersedia dataset preferensi berpasangan IndoPref yang dinilai langsung oleh anotator berbahasa Indonesia dan memuat 522 *prompt* serta 4.099 pasangan preferensi lintas 10 domain [14]. Namun, hasil evaluasi pada dataset IndoPref menunjukkan bahwa akurasi *judge* tertinggi baru mencapai 74,34% (pada Gemini 2.5 Pro), dan penerjemahan *prompt* instruksi evaluasi dari bahasa Inggris ke Bahasa Indonesia menurunkan akurasi model hingga 6,39 poin persentase (dari 69,84% menjadi 63,45% pada GPT-4.1) [14].

Beberapa pendekatan telah digunakan dalam penelitian terdahulu untuk mengevaluasi dan menangani ketidakstabilan *LLM-as-a-Judge*, yaitu evaluasi kecocokan satu arah terhadap label acuan manusia tanpa menukar posisi jawaban [3][14], pengujian dua urutan yang menetapkan hasil penilaian tidak konsisten (*inconsistent*) antara urutan A–B dan B–A sebagai seri (*tie*) [1][4], penggabungan keputusan dari beberapa model penilai (*ensemble judge*) [13], serta pengujian reliabilitas yang memeriksa pengaruh pertukaran posisi jawaban [5][8] dan variasi *prompt* [6][7]. Sejauh ini, penelitian yang menguji *position bias* [1][5], sensitivitas variasi *prompt* [6][7], serta koreksi metrik kesepakatan terhadap peluang kebetulan [9][10] umumnya dilakukan pada dataset berbahasa Inggris. Sementara itu, penelitian pada dataset IndoPref [14] baru mengukur akurasi satu arah tanpa memisahkan pengaruh posisi jawaban dan variasi *prompt* berbahasa Indonesia yang bermakna sama. Oleh karena itu, penelitian khusus Bahasa Indonesia yang menggunakan *human preference* sebagai

acuan sekaligus menguji pengaruh posisi jawaban dan variasi *prompt* secara terpisah masih terbatas. Penelitian ini memilih pendekatan pengujian dengan mengubah satu faktor dalam satu waktu (*one factor at a time*), karena evaluasi satu arah tidak dapat mendeteksi perubahan keputusan saat urutan jawaban dibalik, penetapan hasil *tie* menutupi besarnya persentase perubahan keputusan (*flip rate*), sedangkan metode *ensemble* membutuhkan inferensi dari beberapa model sekaligus tanpa memisahkan sumber ketidakkonsistenan pada masing-masing model.

Penelitian ini menguji reliabilitas model terbuka (*open-weight*) `Qwen/Qwen3-32B` dalam mode *non-thinking* [15] sebagai model *judge* tunggal pada 519 sampel unik lintas 10 domain dari dataset IndoPref [14], agar perubahan keputusan yang diamati tidak tercampur dengan perbedaan karakteristik antarmodel. Pengujian dijalankan pada enam kondisi kombinasi yang terdiri atas dua urutan posisi jawaban (kondisi A–B dan B–A) serta tiga variasi *prompt* berbahasa Indonesia yang bermakna sama, yaitu *prompt baseline* perbandingan menyeluruh (P1), *prompt* multi-kriteria yang mencakup akurasi, relevansi, dan kejelasan (P2), serta *prompt* mitigasi bias (P3), dengan total 3.114 inferensi. Hasil pengujian dianalisis dengan membandingkan kedua posisi jawaban pada *prompt* yang sama serta membandingkan ketiga variasi *prompt* pada posisi jawaban yang sama. Dibandingkan evaluasi satu arah yang hanya melaporkan akurasi mentah pada satu urutan dan satu *prompt*, pendekatan ini dapat mengukur kesepakatan terhadap preferensi manusia menggunakan metrik *accuracy* dan Cohen's kappa [9][10]. Selain itu, pendekatan ini memisahkan besarnya ketidakkonsistenan akibat perubahan posisi jawaban melalui *position consistency*, *preference flip rate*, dan *first-position preference rate* [5][9], serta ketidakkonsistenan akibat variasi *prompt* melalui *prompt consistency* dan *prompt flip rate* [6][7]. Berdasarkan latar belakang tersebut, penelitian ini bertujuan untuk mengukur dan menganalisis tingkat konsistensi keputusan `Qwen/Qwen3-32B` sebagai *LLM-as-a-Judge* terhadap *human preference* pada respons Bahasa Indonesia dalam dataset IndoPref, serta menganalisis pengaruh perubahan posisi jawaban dan variasi *prompt* terhadap konsistensi keputusannya.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Seberapa konsisten keputusan *LLM-as-a-Judge* dengan *human preference* pada respons Bahasa Indonesia?

2. Bagaimana perubahan posisi jawaban (A–B dan B–A) memengaruhi konsis-

tensi keputusan *LLM-as-a-Judge*?

3. Bagaimana variasi *prompt* memengaruhi konsistensi keputusan *LLM-as-a-Judge*?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diidentifikasi, tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Mengukur tingkat konsistensi keputusan *LLM-as-a-Judge* terhadap *human preference* pada respons Bahasa Indonesia menggunakan metrik *accuracy* dan Cohen's kappa.

2. Menganalisis pengaruh perubahan posisi jawaban (A–B dan B–A) terhadap konsistensi keputusan *LLM-as-a-Judge* menggunakan metrik *position consistency*, *preference flip rate*, dan *first-position preference rate*.

3. Menganalisis pengaruh variasi *prompt* yang bermakna sama (*semantically equivalent*) terhadap konsistensi keputusan *LLM-as-a-Judge* menggunakan metrik *prompt consistency* dan *prompt flip rate*.

1.4. Manfaat Penelitian

Apabila permasalahan dalam penelitian ini dapat diselesaikan, manfaat yang diharapkan bagi pihak terkait adalah sebagai berikut:

1. **Bagi Peneliti Selanjutnya:** Menjadi referensi dalam mengkaji reliabilitas *LLM-as-a-Judge* pada evaluasi respons Bahasa Indonesia.

2. **Bagi Pengembang dan Praktisi:** Menjadi bahan pertimbangan dalam menyusun *prompt* dan mengantisipasi bias posisi saat menggunakan LLM sebagai penilai otomatis.

1.5. Batasan Masalah

Untuk memperjelas ruang lingkup dan kondisi berlakunya hasil penelitian, batasan masalah dalam penelitian ini ditetapkan sebagai berikut:

1. Model *judge* yang diuji dibatasi pada satu model terbuka (*open-weight*), yaitu `Qwen/Qwen3-32B` dalam mode *non-thinking* dengan kuantisasi 8-bit (`int8`)

pada lingkungan Google Colab satu GPU tanpa *training* atau *fine-tuning*, sehingga temuan penelitian berlaku spesifik pada model dan konfigurasi tersebut.

2. Data pengujian menggunakan 519 sampel unik lintas 10 domain dari dataset IndoPref dengan memanfaatkan label *reference human preference* yang tersedia tanpa perekrutan anotator baru.

3. Pengujian posisi jawaban dilakukan pada perbandingan berpasangan dua urutan, yaitu kondisi A–B (jawaban pertama ditempatkan pada posisi A dan jawaban kedua pada posisi B) serta kondisi B–A (jawaban kedua ditempatkan pada posisi A dan jawaban pertama pada posisi B).

4. Variasi *prompt* menggunakan tiga instruksi berbahasa Indonesia yang bermakna sama (*semantically equivalent*), yaitu *baseline* perbandingan menyeluruh (P1), multi-kriteria (P2), dan mitigasi bias (P3).

5. Keluaran eksperimen utama dibatasi pada pilihan biner (`A` atau `B`) tanpa penalaran *Chain-of-Thought*.

1.6. Hipotesis Penelitian

Berdasarkan permasalahan yang telah diuraikan mengenai pengaruh posisi jawaban dan variasi *prompt*, hipotesis yang diajukan dalam penelitian ini adalah sebagai berikut:

1. Perubahan posisi jawaban dapat menyebabkan perubahan keputusan *LLM-as-a-Judge* dan menurunkan konsistensi keputusan terhadap *human preference*.

2. Variasi *prompt* yang bermakna sama (*semantically equivalent*) dapat menyebabkan perubahan keputusan *LLM-as-a-Judge* dan memengaruhi konsistensinya terhadap *human preference*.

1.7. Jadwal Penelitian

Jadwal pelaksanaan penelitian ini disusun selama enam bulan sebagaimana ditunjukkan pada Tabel 1.1.

Tabel 1.1: Jadwal penelitian tugas akhir.

No	Kegiatan	Bulan ke-																					
		1				2				3				4				5				6			
1	Studi Literatur																								
2	Penyiapan dan Prapemrosesan Data IndoPref																								
3	Perancangan Prompt dan Konfigurasi Uji																								
4	Pelaksanaan Eksperimen Inferensi																								
5	Analisis Reliabilitas dan Evaluasi Statistik																								
6	Penulisan Laporan Tugas Akhir																								

Tabel 1.1 menyajikan tahapan pengerjaan Tugas Akhir mulai dari studi literatur, penyiapan data, perancangan dan pelaksanaan eksperimen, analisis hasil, hingga penulisan laporan.

BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Tinjauan pustaka ini merangkum penelitian terdahulu yang berkaitan dengan reliabilitas *LLM-as-a-Judge* sebagai acuan dan pembanding bagi Tugas Akhir ini. Tabel 2.1 menyajikan sepuluh penelitian terdahulu pada rentang tahun 2023–2026 yang relevan dengan tiga fokus utama penelitian, yaitu bias posisi jawaban (*position bias*), sensitivitas terhadap variasi *prompt* (*prompt sensitivity*), serta evaluasi pada Bahasa Indonesia atau lintas bahasa. Setiap penelitian diuraikan berdasarkan pembahasan, metode, kelebihan dan kekurangan, serta perbedaannya dengan penelitian ini.

Tabel 2.1: Ringkasan penelitian terdahulu.

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
1	*Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena* (2023) [1]	Penelitian ini menguji penggunaan LLM sebagai penilai dialog terbuka. GPT-4 mencapai kesepakatan $> 80\%$ dengan manusia pada pasangan penilaian yang tidak berakhir seri (*non-tie*), tetapi konsistensi posisi *prompt* standar hanya 23,8%–65,0% pada pasangan respons yang setara.	*Pairwise comparison*, *single-answer*, dan *reference-guided grading* pada GPT-4, GPT-3.5, serta Claude-v1 dengan mitigasi *swap-tie*.	**Kelebihan:** Divalidasi terhadap anotator ahli dan data *crowdsourcing* berskala besar. **Kekurangan:** Berbahasa Inggris, hanya memakai kecocokan mentah, dan aturan *tie* menutupi besarnya *flip rate*.	Menguji respons Bahasa Indonesia IndoPref pada `Qwen/Qwen3-32B` dengan keluaran biner, Cohen's kappa, serta variasi *prompt*.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
2	*Split and Merge: Aligning Position Biases in LLM-based Evaluators* (2024) [16]	Penelitian ini mengkaji bias posisi pada 11.520 evaluasi pasangan MT-Bench. Konsistensi awal bervariasi (Claude2 28,28% *relation-based*; GPT-4 61,50% *likert-based* dengan $> 78\%$ kasus tidak konsisten memilih posisi kedua), dan meningkat relatif 47,46% dengan PORTIA.	Metode *split-and-merge* (PORTIA) pada enam model *judge* dengan format *relation-based*, *score-based*, dan *likert-based*.	**Kelebihan:** Menunjukkan pengaruh format penilaian terhadap arah bias tanpa *fine-tuning*. **Kekurangan:** Jumlah token masukan bertambah panjang, gagal 17,13% pada tugas kode, dan khusus bahasa Inggris.	Tidak memecah teks jawaban, melainkan menguji pengaruh posisi jawaban (A–B dan B–A) serta tiga variasi *prompt* Bahasa Indonesia.
3	*Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge* (2025) [5]	Penelitian ini menganalisis *position bias* pada > 150.000 evaluasi MT-Bench dan DevBench. Stabilitas pengulangan umumnya $> 0,85$ pada model *judge* yang andal sehingga menunjukkan bias bersifat sistematis, sedangkan konsistensi posisi (0,57–0,82 di MT-Bench) turun saat kualitas kedua jawaban hampir setara.	Pertukaran urutan posisi *pairwise* dan *listwise* pada 15 *judge* memakai *repetition stability*, *position consistency*, *preference fairness*, dan regresi.	**Kelebihan:** Memisahkan bias sistematis dari variasi acak serta mengukur pengaruh selisih kualitas jawaban. **Kekurangan:** Tidak menguji variasi *prompt* dan terbatas pada bahasa Inggris.	Menggabungkan pengujian posisi jawaban dengan tiga variasi *prompt* Bahasa Indonesia yang bermakna sama terhadap acuan manusia IndoPref.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
4	*Diagnosing Bias and Instability in LLM Evaluation: A Scalable Pairwise Meta-Evaluator* (2025) [8]	Penelitian ini menguji 3.600 perbandingan (1.800 pasangan bolak-balik A–B dan B–A). Sebanyak 48,4% keputusan berbalik saat posisi jawaban ditukar meskipun tiga *judge* bersepakat 100%, dan penambahan instruksi anti-bias hanya memberi perbaikan terbatas.	Pengujian berpasangan dua arah, perubahan kata serta parafrase, dan penambahan aturan anti-bias pada LLaMA 3:8B, OpenHermes, serta Nous-Hermes 2.	**Kelebihan:** Menunjukkan bahwa kesepakatan 100% antar-*judge* tetap dapat menyimpan bias posisi yang sama. **Kekurangan:** Hanya memakai 10 soal bahasa Inggris tanpa label acuan manusia.	Mengevaluasi 519 sampel unik dari 10 domain Bahasa Indonesia yang memiliki label *reference human preference*.
5	*Systematic Evaluation of LLM-as-a-Judge in LLM Alignment Tasks: Explainable Metrics and Diverse Prompt Templates* (2025) [6]	Penelitian ini menguji variasi *template prompt* pada tugas peringkasan dan dialog. Akurasi dua urutan berada di bawah $0,7$ (turun hingga $< 0,2$ pada *template* yang kurang sesuai), dan pergantian *template* dapat membalik arah *position bias*.	Pertukaran posisi jawaban dengan koreksi *flipping noise* pada tiga model OpenAI memakai 8 *template* TL;DR dan 10 *template* HH-RLHF.	**Kelebihan:** Menunjukkan hubungan antara pilihan *template*, arah bias posisi, dan akurasi. **Kekurangan:** Hanya menguji model tertutup OpenAI pada data berbahasa Inggris.	Menguji model terbuka (*open-weight*) `Qwen/Qwen3-32B` pada Bahasa Indonesia dengan tiga variasi *prompt* yang bermakna sama.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
6	*JudgeSense: A Benchmark for Prompt Sensitivity in LLM-as-a-Judge Systems* (2026) [7]	Penelitian ini mengukur sensitivitas model terhadap parafrase instruksi yang bermakna sama. Perubahan kalimat menurunkan konsistensi di empat tugas, skala ordinal 1–5 jauh kurang stabil dibandingkan biner, dan ukuran parameter dalam satu keluarga model tidak menjamin stabilitas.	Pengujian 880 sampel berlabel manusia pada 25 *judge* (termasuk Qwen3) melalui selisih kesepakatan parafrase dan pengulangan (ΔJSS).	**Kelebihan:** Memisahkan pengaruh perubahan kalimat instruksi dari pengaruh pengulangan inferensi. **Kekurangan:** Terbatas pada bahasa Inggris dan hanya menilai respons tunggal (*pointwise*) tanpa menguji pertukaran posisi jawaban.	Menguji perbandingan berpasangan (*pairwise*) Bahasa Indonesia IndoPref dengan tiga variasi *prompt* yang bermakna sama (P1, P2, P3) pada urutan posisi A–B dan B–A.
7	*The Coin Flip Judge? Reliability and Bias in LLM-as-a-Judge Evaluation* (2026) [17]	Penelitian ini menguji kestabilan keputusan pada pasangan jawaban yang setara. Hasil pengulangan berbalik rata-rata 13,6%, GPT-4o-mini memilih posisi pertama pada 72% soal, muncul *pairwise–pointwise gap*, dan *template* yang bermakna sama mengubah pemenang mayoritas pada 25% kasus.	Pengulangan 50 *trial* *pairwise* dan *pointwise* pada GPT-4o-mini serta GPT-4.1-mini di 29 soal, disertai pengujian $T = 0$ dan dua *template*.	**Kelebihan:** Menunjukkan ketidakkonsistenan pada jawaban yang setara yang tetap muncul pada $T = 0$. **Kekurangan:** Hanya menguji dua model OpenAI pada 29 soal bahasa Inggris tanpa label manusia.	Mengevaluasi 519 sampel Bahasa Indonesia berlabel preferensi manusia pada model *open-weight* dengan tiga variasi *prompt* dan dua posisi jawaban.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
8	*Reliability without Validity: A Systematic, Large-Scale Evaluation of LLM-as-a-Judge Models Across Agreement, Consistency, and Bias* (2026) [9]	Penelitian ini mengevaluasi 21 *judge* ($\sim$ 541.000 penilaian) dan menemukan *kappa deflation* sebesar 33,8–41,3 poin persentase di MT-Bench serta *consistency–bias paradox* pada model dengan konsistensi pengulangan Krippendorff's $\alpha > 0,95$ yang tetap memiliki bias posisi tinggi.	Pengujian *agreement*, *consistency*, dan *bias audit* ($T = 0$) di MT-Bench, JudgeBench, serta RewardBench memakai *exact match*, Cohen's kappa, dan *flip rate*.	**Kelebihan:** Menunjukkan pentingnya penggunaan Cohen's kappa bersama pengujian posisi jawaban. **Kekurangan:** Hanya memakai satu *template* bahasa Inggris tanpa variasi *prompt*.	Menerapkan *accuracy*, Cohen's kappa, dan pengujian posisi jawaban pada Bahasa Indonesia sekaligus menguji tiga variasi *prompt*.
9	*How Reliable is Multilingual LLM-as-a-Judge?* (2025) [13]	Penelitian ini menguji konsistensi penilaian lintas 25 bahasa paralel (termasuk 142 sampel Bahasa Indonesia pada WikiLingua). Rata-rata konsistensi masih rendah (Fleiss' kappa $\approx 0,3$), format biner lebih stabil daripada skala 1–5, dan ukuran model tidak menjamin konsistensi.	Evaluasi *pointwise* (biner *Yes/No* dan skala 1–5) pada lima *judge* di lima dataset paralel memakai Fleiss' kappa, Cohen's kappa, dan *ensemble*.	**Kelebihan:** Mengukur ketidakkonsistenan lintas bahasa dan menunjukkan kestabilan format biner. **Kekurangan:** Hanya menguji skema *pointwise* dengan *prompt* bahasa Inggris tanpa pertukaran posisi.	Berfokus pada perbandingan *pairwise* dengan teks jawaban, *prompt*, dan preferensi manusia berbahasa Indonesia.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
10	*IndoPref: A Multi-Domain Pairwise Preference Dataset for Indonesian* (2025) [14]	Penelitian ini membangun dataset preferensi berpasangan Bahasa Indonesia (522 *prompt*, 4.099 pasangan lintas 10 domain, Krippendorff's $\alpha = 0,891$) serta menguji 15 model. Akurasi tertinggi mencapai 74,34%, dan terjemahan *prompt* ke Bahasa Indonesia menurunkan akurasi GPT-4.1 sebesar 6,39 poin persentase.	Penilaian anotator berbahasa Indonesia dikonversi menjadi preferensi berpasangan, lalu diuji akurasinya pada satu urutan menggunakan 12 model *open-weight* dan 3 model tertutup.	**Kelebihan:** Menyediakan dataset *human preference* asli Bahasa Indonesia lintas 10 domain. **Kekurangan:** Hanya mengukur akurasi satu urutan tanpa pertukaran posisi A–B dan B–A, tanpa Cohen's kappa, serta tanpa variasi *prompt*.	Menggunakan IndoPref untuk menguji reliabilitas `Qwen/Qwen3-32B` pada pertukaran posisi jawaban (A–B dan B–A), tiga variasi *prompt* yang bermakna sama, dan Cohen's kappa.

Perbandingan penelitian pada Tabel 2.1 beserta literatur terkait menunjukkan bahwa evaluasi *LLM-as-a-Judge* tidak cukup hanya dilihat dari persentase kecocokan rata-rata, melainkan perlu mengukur kesepakatan terhadap penilaian manusia sekaligus konsistensi keputusan model itu sendiri. Penelitian awal melaporkan bahwa model penilai dapat mencapai kecocokan di atas 80% dengan manusia pada dialog terbuka [1], tetapi pengujian lintas 20 tugas pemrosesan bahasa alami menunjukkan tingkat kesepakatan yang sangat bervariasi antartugas [3], bahkan mendekati tebakan acak pada tugas verifikasi objektif ketika diuji dalam dua urutan posisi jawaban [18]. Dari sisi metrik evaluasi, persentase kecocokan mentah belum cukup menggambarkan kualitas penilai karena model dengan kecocokan rata-rata di atas 90% masih dapat berselisih lebih dari 10 poin persentase terhadap skor manusia [19]. Selain itu, nilai kecocokan mentah terbukti lebih tinggi 33,8–41,3 poin persentase dibandingkan Cohen's kappa pada MT-Bench (*kappa deflation*) karena belum memperhitungkan peluang kebetulan [9], serta mudah berubah akibat perbedaan cara menangani kasus ketika model tidak memberikan pilihan jawaban, keluaran *invalid*, dan ketimpangan proporsi label [10]. Temuan bahwa tiga model *judge* yang bersepakat 100% tetap membalik 48,4% keputusannya saat posisi jawaban ditukar [8], serta tingginya konsistensi pengulangan (Krippendorff's $\alpha = 0,992$ di MT-Bench) pada model yang memiliki bias posisi besar seperti Qwen 3 8B [9], turut menunjukkan adanya *consistency–bias paradox*, yaitu keluaran yang deterministik belum tentu bebas dari bias sistematis.

Hasil penelitian terdahulu juga menunjukkan bahwa arah *position bias* dan *prompt sensitivity* berbeda-beda antarmodel maupun antarpengaturan uji. Beberapa penelitian menemukan kecenderungan kuat untuk memilih jawaban pada posisi pertama (*primacy bias*), seperti 75,0% pada Claude-v1 [1] dan 72% kemenangan mayoritas posisi pertama pada GPT-4o-mini [17], sedangkan penelitian lain melaporkan kecenderungan memilih jawaban pada posisi kedua (*recency bias*), seperti lebih dari 78% kasus tidak konsisten pada GPT-4 dengan format Likert [16] serta perbedaan tanda nilai *preference fairness* antarmodel [5]. Ketidakkonsistenan akibat posisi ini semakin besar ketika kualitas kedua jawaban hampir setara [5][17]. Selain itu, bias posisi berkaitan erat dengan penyusunan *prompt* karena pergantian *template* pada model yang sama dapat menggeser akurasi sekaligus membalik arah *position bias* [6]. Bahkan ketika instruksi ditulis ulang dengan makna yang sama (*semantically equivalent*), konsistensi keputusan tetap turun melebihi pengaruh pengulangan inferensi (*decoding noise*) [7] dan mengubah pemenang mayoritas pada 25% kasus [17], sementara ukuran parameter yang lebih besar dalam satu keluarga model tidak menjamin kestabilan keputusan terhadap perubahan kalimat *prompt* [7].

Meskipun berbagai sumber ketidakstabilan tersebut telah banyak diteliti, sebagian besar pengujian masih berfokus pada bahasa Inggris. Hanya 33 dari 650 publikasi *LLM-as-a-Judge* (5,1%) di ACL Anthology yang meneliti konteks multibahasa atau bahasa dengan keterbatasan data (*low-resource*), dan banyak di antaranya belum disertai validasi manusia yang memadai pada bahasa yang diuji [12]. Padahal, pengujian lintas bahasa menunjukkan konsistensi penilaian yang rendah dengan rata-rata Fleiss' kappa sekitar 0,3 [13], skor penilaian yang cenderung mengumpul di nilai tengah (*score convergence*) pada bahasa *low-resource* [20], perbedaan akurasi antarbahasa serta bias terhadap bahasa jawaban tertentu [21], dan meningkatnya ketidakkonsistenan posisi ketika bahasa pengujian bergeser dari bahasa Inggris [22]. Penelitian multibahasa yang menyertakan Bahasa Indonesia umumnya baru menggunakan data ringkasan WikiLingua dengan skema *pointwise* [13], data hasil terjemahan mesin [23], atau pasangan opsi soal pilihan ganda terjemahan MMMLU [21]. Sementara itu, pengujian pada dataset preferensi berpasangan Bahasa Indonesia IndoPref [14] baru mengukur akurasi pada satu urutan jawaban dan satu terjemahan *prompt* tanpa menguji pertukaran posisi jawaban maupun variasi *prompt*. Oleh karena itu, meskipun keberadaan *position bias* dan *prompt sensitivity* pada *LLM-as-a-Judge* telah banyak dibuktikan pada bahasa Inggris, penelitian khusus Bahasa Indonesia yang mengacu pada *human preference* serta menguji pengaruh posisi jawaban dan variasi *prompt* secara terpisah masih terbatas.

2.2. Landasan Teori

Bagian ini menguraikan konsep dan dasar teori yang digunakan dalam pelaksanaan penelitian serta analisis pada bab-bab berikutnya. Pembahasan mencakup konsep *large language model* (LLM), metode *LLM-as-a-Judge*, ukuran reliabilitas model penilai, *position bias*, *prompt sensitivity*, evaluasi LLM pada Bahasa Indonesia, serta sintesis teori dan celah penelitian.

2.2.1. Large Language Models

Large language model (LLM) adalah model bahasa generatif berbasis jaringan saraf tiruan berskala besar yang memodelkan distribusi probabilitas kondisional atas barisan token secara autoregresif [2]. Melalui tahap prapelatihan pada kumpulan data teks berukuran besar, model mempelajari pola bahasa dan pengetahuan lintas domain untuk memprediksi token berikutnya berdasarkan teks masukan. Agar dapat mengikuti perintah pengguna dengan tepat, model dilatih lebih lanjut melalui penyelarasan instruksi (*instruction tuning*) dan preferensi manusia sehingga menghasilkan model *instruction-tuned* yang mampu memahami instruksi peran, kriteria penilaian, serta aturan format keluaran secara langsung pada saat inferensi [2][4].

Kemampuan tersebut memungkinkan pelaksanaan evaluasi berbasis inferensi (*inference-based evaluation*) dengan menggunakan bobot parameter model secara langsung tanpa pelatihan ulang atau *fine-tuning* [2][4]. Pada pendekatan ini, keputusan model ditentukan oleh interaksi antara bobot hasil pelatihan, susunan isi *prompt* masukan, serta pengaturan dekoding seperti *temperature* dan batas maksimum token keluaran [7]. Salah satu model terbuka (*open-weight*) yang mendukung pendekatan ini adalah `Qwen/Qwen3-32B`, yaitu model *dense* terbesar pada keluarga Qwen3 berukuran 32 miliar parameter yang dilatih pada 36 triliun token lintas 119 bahasa dan dialek termasuk Bahasa Indonesia [15]. Model ini menggabungkan mode penalaran (*thinking*) dan mode respons langsung (*non-thinking*) dalam satu model yang sama, sehingga pengaktifan mode *non-thinking* memungkinkan model menghasilkan label keputusan secara langsung tanpa tahapan penalaran internal [15]. Pada pengujian *benchmark* Bahasa Indonesia dalam mode *non-thinking* yang mencakup INCLUDE, MMMLU, MT-AIME24, dan PolyMath, `Qwen/Qwen3-32B` memperoleh rata-rata skor 51,6 (dengan skor 81,8 pada INCLUDE dan 77,2 pada MMMLU), yang merupakan capaian tertinggi di antara seluruh model *dense* yang diuji serta melampaui model pembanding seperti `Gemma-3-27b-IT` (47,0), `GPT-4o-2024-1120` (46,4), dan `Qwen2.5-72B-Instruct` (45,0) [15].

2.2.2. LLM-as-a-Judge

LLM-as-a-Judge adalah metode evaluasi otomatis yang menggunakan LLM untuk menilai kualitas keluaran teks berdasarkan instruksi, kriteria, atau preferensi yang tertulis di dalam *prompt* [1][2]. Mengadaptasi formalisasi evaluasi berbasis LLM [2][4], apabila x menyatakan instruksi tugas awal, $\mathscr{R}$ menyatakan pasangan jawaban yang dinilai, dan $\mathscr{C}$ menyatakan instruksi *prompt* evaluasi, maka model memetakan seluruh masukan tersebut melalui distribusi probabilitas kondisional $\mathscr{P}_{\text{LLM}}$ dan fungsi ekstraksi keluaran $g(\cdot)$ menjadi label keputusan $\hat{y} = g(\mathscr{P}_{\text{LLM}}(x, \mathscr{R}, \mathscr{C}))$.

Metode penilaian ini secara umum terbagi menjadi skema penilaian tunggal (*pointwise*) dan perbandingan berpasangan (*pairwise comparison*) [1][4]. Skema *pointwise* menilai setiap respons secara terpisah dalam bentuk skor angka, tetapi rentan terhadap ketidakkonsistenan skala nilai [16], menyempitnya rentang skor pada bahasa *low-resource* [20], serta variasi nilai pada soal yang sama sehingga menyulitkan pembedaan dua jawaban yang kualitasnya hampir setara [1][4][17]. Sebaliknya, *pairwise comparison* membandingkan dua jawaban secara langsung untuk instruksi yang sama dan terbukti lebih selaras dengan preferensi manusia ketika perbedaan kualitas kedua jawaban cukup tipis [1][4]. Pembatasan keluaran model menjadi pilihan biner (`A` atau `B`) juga menghindari ketidakkonsistenan penentuan batas nilai antarkategori yang terbukti jauh lebih besar pada penilaian berskala ordinal 1–5 [7][13]. Namun, penyajian dua jawaban secara berurutan di dalam satu *prompt* membuat skema berpasangan rentan terhadap bias posisi [2] serta dapat memaksakan penentuan pemenang meskipun selisih skor kedua jawaban pada penilaian tunggal sangat kecil (*pairwise–pointwise gap*) [17].

2.2.3. Reliabilitas LLM Judge

Reliabilitas *LLM-as-a-Judge* mencakup dua aspek utama, yaitu kesepakatan keputusan model dengan preferensi manusia (*human agreement*) dan konsistensi keputusan model ketika cara penyajiannya diubah tanpa mengubah isi jawaban yang dinilai [2][9]. Kedua aspek ini perlu diukur bersama karena model yang memberikan hasil tetap saat diuji berulang pada masukan yang sama masih dapat menyimpan bias sistematis yang menyimpang dari preferensi manusia [8][9], serta menggeser peringkat kualitas model apabila hasil penilaiannya digabungkan tanpa memperhitungkan keandalan penilai [11]. Oleh karena itu, reliabilitas dalam penelitian ini diukur melalui kesepakatan terhadap *human preference*, konsistensi terhadap posisi jawaban, dan konsistensi terhadap variasi *prompt*.

Tingkat kesepakatan terhadap *reference human preference* pertama-tama di-

ukur menggunakan proporsi kecocokan keputusan valid (*accuracy*) pada Persamaan (2.1):

$$\text{Accuracy} = \frac{1}{N_{\text{valid}}} \sum_{i=1}^{N_{\text{valid}}} \mathbb{I}(\hat{y}_i = y_i) \tag{2.1}$$

dengan N_{valid} adalah jumlah keputusan biner yang valid (`A` atau `B`), $\hat{y}_i \in \{\texttt{A}, \texttt{B}\}$ adalah keputusan *judge*, $y_i \in \{\texttt{A}, \texttt{B}\}$ adalah label acuan manusia, dan $\mathbb{I}(\cdot)$ adalah fungsi indikator yang bernilai 1 jika kondisi di dalamnya benar serta 0 jika salah. Karena *accuracy* belum memperhitungkan kesepakatan yang terjadi secara kebetulan [10][19] sehingga nilainya dapat jauh lebih tinggi daripada kesepakatan terkoreksi peluang (*kappa deflation*) [9], pengukurannya dilengkapi dengan Cohen's kappa (κ) [9][10] pada Persamaan (2.2):

$$\kappa = \frac{P_o - P_e}{1 - P_e} \tag{2.2}$$

dengan $P_o = \text{Accuracy}$ dan $P_e = P(y = \texttt{A})P(\hat{y} = \texttt{A}) + P(y = \texttt{B})P(\hat{y} = \texttt{B})$ sebagai peluang kesepakatan kebetulan berdasarkan proporsi pilihan label manusia dan *judge*. Mengingat nilai *accuracy* maupun κ sangat dipengaruhi oleh cara penanganan keluaran yang gagal (*invalid*), keluaran model yang tidak menghasilkan label biner `A` atau `B` tidak dimasukkan ke salah satu kelas, melainkan dipisahkan dan dilaporkan persentasenya melalui *invalid rate* [10].

2.2.4. Position Bias

Position bias adalah kecenderungan sistematis model penilai untuk memilih salah satu jawaban berdasarkan urutan penempatannya di dalam *prompt*, terlepas dari isi respons yang dinilai [1][5]. Bias ini terjadi ketika pertukaran posisi jawaban mengubah keputusan akhir ($\text{LLM}(x, R_{\text{A}}, R_{\text{B}}) \neq \text{LLM}(x, R_{\text{B}}, R_{\text{A}})$) [16], baik berupa kecenderungan memilih jawaban di posisi pertama (*primacy bias*) maupun di posisi kedua (*recency bias*) [5], dan semakin kuat ketika kualitas kedua jawaban hampir setara [4][5].

Pengujian *position bias* dilakukan melalui pertukaran posisi jawaban antara kondisi A–B (Respons A ditempatkan pada posisi pertama, Respons B pada posisi kedua) dan kondisi B–A (Respons B ditempatkan pada posisi pertama, Respons A pada posisi kedua) dengan tetap mempertahankan `A` serta `B` sebagai identitas jawaban asli [1][5][8]. Tanpa mengubah keputusan yang berlawanan menjadi hasil seri (*tie*), pengaruh posisi jawaban diukur menggunakan *position consistency*, *preference flip rate*, dan *first-position preference rate* pada Persamaan (2.3)–(2.5) yang diadaptasi

dari metrik evaluasi bias posisi [5][9][17]:

$$\text{Position Consistency} = \frac{1}{N_{\text{pos}}} \sum_{i=1}^{N_{\text{pos}}} \mathbb{I}\left(\hat{y}_{i,\text{AB}} = \hat{y}_{i,\text{BA}}\right) \tag{2.3}$$

$$\text{Preference Flip Rate} = \frac{1}{N_{\text{pos}}} \sum_{i=1}^{N_{\text{pos}}} \mathbb{I}\left(\hat{y}_{i,\text{AB}} \neq \hat{y}_{i,\text{BA}}\right) = 1 - \text{Position Consistency} \tag{2.4}$$

$$\text{First-Position Preference Rate} = \frac{1}{2N_{\text{pos}}} \sum_{i=1}^{N_{\text{pos}}} \left[\mathbb{I}\left(\hat{y}_{i,\text{AB}} = \texttt{A}\right) + \mathbb{I}\left(\hat{y}_{i,\text{BA}} = \texttt{B}\right)\right] \tag{2.5}$$

dengan N_{pos} menyatakan jumlah pasangan sampel yang memiliki keputusan valid pada kedua urutan, serta $\hat{y}_{i,\text{AB}}, \hat{y}_{i,\text{BA}} \in \{\texttt{A}, \texttt{B}\}$ menyatakan identitas jawaban asli yang dipilih. Pada pengujian dua urutan yang seimbang, *first-position preference rate* digunakan untuk membedakan perubahan keputusan yang bersifat acak dari kecenderungan sistematis untuk memilih jawaban di posisi pertama (nilai $> 0,50$) atau posisi kedua (nilai $< 0,50$).

2.2.5. Prompt Sensitivity

Prompt sensitivity adalah ketidakstabilan keputusan *LLM-as-a-Judge* akibat perubahan kalimat instruksi, rincian kriteria penilaian, atau aturan tambahan di dalam *prompt* meskipun tujuan evaluasi dan pasangan jawaban yang dinilai tetap sama [2][6][7]. Karena proses dekoding autoregresif bergantung pada susunan kata dan token di dalam *prompt*, perbedaan struktur *template* maupun variasi kalimat yang bermakna sama (*semantically equivalent*) tetap dapat menggeser fokus penilaian model serta mengubah arah bias posisinya [6][7].

Penyusunan *prompt* evaluasi terstruktur dengan komponen peran, konteks, tugas penilaian, dan format keluaran umumnya mencakup tiga pendekatan, yaitu perbandingan menyeluruh secara langsung (*baseline*) [1][2], perincian rubrik multi-kriteria seperti akurasi, relevansi, dan kejelasan untuk memperjelas dasar penilaian [2][4], serta penambahan aturan eksplisit anti-bias agar model mengabaikan urutan jawaban [1][8] dan panjang respons [1]. Penalaran bertahap (*Chain-of-Thought*) atau penulisan penjelasan sebelum keputusan tidak digunakan pada pengujian utama agar keluaran model tetap berupa label biner, mengingat permintaan penjelasan bersamaan dengan keputusan terbukti dapat menurunkan konsistensi posisi [2] serta penambahan instruksi penalaran bertahap dapat mengubah keputusan mayoritas model [17]. Pada posisi jawaban yang sama, konsistensi keputusan lintas tiga variasi *prompt* (P1, P2, dan P3) diukur menggunakan *prompt consistency* serta *prompt flip rate* antarpasangan *prompt* pada Persamaan (2.6) dan Persamaan (2.7) yang

diadaptasi dari pengujian sensitivitas *prompt* [7][17]:

$$\text{Prompt Consistency} = \frac{1}{N_{\text{prompt}}} \sum_{i=1}^{N_{\text{prompt}}} \mathbb{I}\left(\hat{y}_{i,\text{P1}} = \hat{y}_{i,\text{P2}} = \hat{y}_{i,\text{P3}}\right) \tag{2.6}$$

$$\text{Prompt Flip Rate}_{(p,q)} = \frac{1}{N_{(p,q)}} \sum_{i=1}^{N_{(p,q)}} \mathbb{I}\left(\hat{y}_{i,p} \neq \hat{y}_{i,q}\right) \tag{2.7}$$

dengan N_{prompt} menyatakan jumlah sampel yang menghasilkan keputusan valid pada ketiga variasi *prompt* dan $N_{(p,q)}$ menyatakan jumlah sampel valid pada pasangan $(p,q) \in \{(\text{P1},\text{P2}),(\text{P1},\text{P3}),(\text{P2},\text{P3})\}$. Perhitungan *flip rate* untuk setiap pasangan *prompt* ini digunakan untuk melihat variasi *prompt* mana yang paling banyak mengubah keputusan model.

2.2.6. Evaluasi LLM Bahasa Indonesia

Evaluasi otomatis pada teks Bahasa Indonesia masih menghadapi kendala karena terbatasnya porsi bahasa non-Inggris dalam data pelatihan LLM. Kondisi ini berdampak pada menyempitnya selisih skor penilaian pada bahasa dengan keterbatasan data (*low-resource*) [20], rendahnya konsistensi keputusan lintas bahasa [13], serta munculnya perbedaan performa antarbahasa dan bias terhadap bahasa jawaban tertentu [21]. Dataset evaluasi yang diterjemahkan dari bahasa Inggris juga sering kali kehilangan kealamian kalimat serta konteks budaya lokal [14], sedangkan penggunaan data terjemahan mesin dalam pelatihan penilai multibahasa terbukti menurunkan ketepatan model pada data pengujian yang ditulis langsung dalam bahasa sasaran [23]. Di samping itu, penerjemahan instruksi *prompt* evaluasi ke Bahasa Indonesia terbukti dapat menurunkan akurasi penilai [14], sementara perubahan bahasa penyajian dari bahasa Inggris memicu perubahan keputusan sebesar 10,7%–14,4% sekaligus meningkatkan ketidakkonsistenan posisi jawaban dari 12,1% menjadi 14,9%–18,1% [22].

Untuk menyediakan acuan evaluasi Bahasa Indonesia yang disusun dan dinilai langsung oleh anotator berbahasa Indonesia, dataset IndoPref memuat 522 *prompt* lintas 10 domain (*Analysis*, *Brainstorming*, *Coding*, *Creative Writing*, *Logic*, *Math*, *Open Question*, *Safety*, *Summarization*, dan *Translation*) beserta 4.099 pasangan preferensi atas respons lima LLM *instruction-tuned* dengan tingkat kesepakatan antar-anotator Krippendorff's $\alpha = 0,891$ [14]. Dalam penelitian ini, label pada IndoPref digunakan sebagai *reference human preference* sesuai prosedur anotasinya, bukan sebagai penilaian mutlak yang mewakili seluruh pengguna Bahasa Indonesia.

2.2.7. Sintesis dan Research Gap

Berdasarkan landasan teori yang telah diuraikan, ketika model *instruction-tuned* digunakan sebagai *pairwise LLM-as-a-Judge*, model memproses isi kedua jawaban sekaligus urutan penempatannya dan kalimat instruksi *prompt* dalam satu distribusi probabilitas kondisional [2][4]. Oleh karena itu, pengujian yang hanya melaporkan akurasi mentah pada satu urutan jawaban dan satu *prompt* belum cukup untuk menilai reliabilitas model. Nilai kecocokan mentah dapat meningkat akibat peluang kebetulan dan ketimpangan proporsi label [10] sehingga memicu *kappa deflation* [9], sedangkan keputusan model tetap rentan berubah akibat *position bias* [5][8] dan *prompt sensitivity* [6][7], terutama pada evaluasi lintas bahasa dan Bahasa Indonesia yang peka terhadap perubahan bahasa penyajian maupun bahasa instruksi *prompt* [13][14][22].

Mengingat penelitian khusus Bahasa Indonesia berbasis *human preference* yang menguji pengaruh posisi jawaban dan variasi *prompt* secara terpisah masih terbatas, landasan teori tersebut digunakan sebagai dasar untuk menjawab rumusan masalah dan menguji hipotesis penelitian. Pertama, pengukuran kesepakatan yang memperhitungkan peluang kebetulan digunakan untuk menilai tingkat konsistensi `Qwen/Qwen3-32B` terhadap *reference human preference* IndoPref melalui metrik *accuracy* dan Cohen's kappa. Kedua, pengujian pertukaran posisi jawaban digunakan untuk menguji hipotesis pertama mengenai pengaruh perubahan urutan A–B dan B–A melalui *position consistency*, *preference flip rate*, dan *first-position preference rate*. Ketiga, penggunaan tiga variasi *prompt* yang bermakna sama (*semantically equivalent*) digunakan untuk menguji hipotesis kedua mengenai pengaruh variasi *prompt* P1, P2, dan P3 melalui *prompt consistency* serta *prompt flip rate* berpasangan, yang tahapannya dijelaskan lebih lanjut pada Bab III.

BAB III

METODE PENELITIAN

Pada bab ini dipaparkan metode penelitian yang digunakan untuk menganalisis reliabilitas *LLM-as-a-Judge* pada variasi *prompt* dan posisi jawaban dalam Bahasa Indonesia. Pembahasan disajikan secara berurutan meliputi subjek dan objek penelitian, alat dan bahan penelitian, serta diagram alir penelitian yang menjadi acuan penyajian hasil pada Bab IV.

3.1. Subjek dan Objek Penelitian

Subjek dalam penelitian ini adalah model terbuka (*open-weight*) `Qwen/Qwen3-32B` [15] yang digunakan sebagai penilai otomatis berpasangan (*pairwise LLM-as-a-Judge*). Model ini merupakan model *dense* berukuran 32 miliar parameter yang dilatih pada 36 triliun token lintas 119 bahasa dan dialek termasuk Bahasa Indonesia, serta dijalankan dalam mode respons langsung (*non-thinking mode*) [15]. Evaluasi dilakukan sepenuhnya berbasis inferensi (*inference-based evaluation*) tanpa pelatihan ulang atau *fine-tuning* [2]. Penggunaan satu model penilai tunggal ditetapkan untuk memisahkan pengaruh perubahan posisi jawaban dan variasi *prompt* agar tidak tercampur dengan perbedaan karakteristik antarmodel.

Objek dalam penelitian ini adalah tingkat reliabilitas keputusan evaluasi berpasangan dari `Qwen/Qwen3-32B` pada pasangan respons berbahasa Indonesia. Pengamatan terhadap objek tersebut difokuskan pada tingkat kesepakatan keputusan model terhadap label acuan preferensi manusia (*reference human preference*), konsistensi serta kecenderungan arah keputusan ketika posisi jawaban ditukar antara urutan standar (A–B) dan urutan terbalik (B–A), serta konsistensi keputusan ketika menggunakan tiga variasi *prompt* berbahasa Indonesia yang bermakna sama (P1, P2, dan P3).

3.2. Alat dan Bahan Penelitian

Bagian ini menguraikan alat penelitian dan bahan penelitian yang digunakan dalam perancangan serta pengujian eksperimen.

3.2.1. Alat Penelitian

Alat penelitian mencakup perangkat keras komputasi untuk menjalankan inferensi model bahasa besar dan pengolahan data, perangkat lunak beserta pustaka pemrograman yang mendukung pengujian serta analisis statistik, variabel penelitian, dan persamaan evaluasi. Rincian perangkat keras dan perangkat lunak yang digunakan disajikan pada Tabel 3.1.

Tabel 3.1: Spesifikasi perangkat keras dan perangkat lunak penelitian.

Kategori	Komponen	Spesifikasi dan Kegunaan
Komputasi Awan (*Remote Runtime*)	Google Colab Pro	*Runtime* Linux berbasis komputasi awan dengan akselerator GPU tunggal NVIDIA A100-SXM4-80GB (VRAM 80 GB) dan *disk* lokal *runtime* untuk menyimpan *cache* bobot model serta menjalankan inferensi.
Penyimpanan Awan	Google Drive	Media penyimpanan berkapasitas 5 TB untuk menyimpan data pengujian, berkas *checkpoint* inferensi, dan hasil evaluasi eksperimen.
Perangkat Keras Lokal	Laptop	Prosesor AMD Ryzen 3 3250U *with Radeon Graphics* (2,60 GHz) dan RAM 8,00 GB (64-bit, x64) sebagai perangkat utama penulisan kode, kendali *remote runtime*, pengolahan hasil, dan penyusunan laporan.
Sistem Operasi dan Terminal	Windows 11, WSL (Kali Linux), PowerShell	Sistem operasi Windows 11 Home Single Language dengan terminal WSL (Kali Linux) dan Windows PowerShell untuk eksekusi perintah baris, pengelolaan lingkungan kerja, serta kompilasi dokumen.
IDE, Dokumen, dan Referensi	VS Code, Jupyter Notebook, LaTeX, Zotero	Lingkungan pengembangan terpadu untuk penulisan kode eksperimen dan laporan (*pdflatex* serta *BibTeX*), pengelolaan sitasi pustaka melalui Zotero, serta eksekusi Jupyter Notebook yang dihubungkan secara *remote* ke *runtime* Google Colab.
Sistem Kontrol Versi	Git & GitHub	Pengelolaan versi (*version control*) dan repositori terpusat untuk kode eksperimen beserta dokumen laporan Tugas Akhir.
Bahasa Pemrograman	Python 3	Bahasa pemrograman utama pada Jupyter Notebook untuk implementasi skenario eksperimen, prapemrosesan data, dan evaluasi statistik.
Pustaka Inferensi dan Kuantisasi	PyTorch, Transformers, BitsAndBytes, Accelerate	Pemuatan model `Qwen/Qwen3-32B` dan *tokenizer*, konfigurasi kuantisasi 8-bit (`int8`), serta eksekusi inferensi model pada GPU.
Pustaka Pengolahan Data	Datasets, Pandas, NumPy, PyArrow	Pengunduhan dataset sekunder, pemeriksaan kelengkapan atribut data, dan pengolahan tabel hasil pengujian.
Pustaka Evaluasi dan Visualisasi	Scikit-learn, Statsmodels, Matplotlib, Seaborn	Perhitungan koefisien kesepakatan, pengujian signifikansi statistik berpasangan, serta pembuatan grafik visualisasi evaluasi.

Berdasarkan Tabel 3.1, penulisan kode pengujian pada Jupyter Notebook serta penyusunan laporan LaTeX dilakukan secara terpusat menggunakan Visual Studio

Code pada laptop dengan dukungan terminal WSL (Kali Linux), Windows PowerShell, dan manajemen referensi Zotero, sedangkan pengelolaan versi kode serta dokumen dilakukan melalui Git dan GitHub. Untuk kebutuhan komputasi model, Jupyter Notebook pada VS Code dihubungkan secara *remote* ke *runtime* Google Colab Pro sehingga GPU NVIDIA A100-SXM4-80GB dan *disk* lokal *runtime* digunakan khusus untuk menyimpan *cache* bobot model serta menjalankan inferensi, sementara Google Drive 5 TB digunakan untuk menyimpan data pengujian dan berkas hasil evaluasi.

Selain perangkat komputasi, alat penelitian mencakup penetapan variabel bebas, variabel terikat, dan variabel kontrol sebagai kerangka pengujian eksperimental yang definisi operasionalnya dirangkum pada Tabel 3.2.

Tabel 3.2: Variabel bebas, variabel terikat, dan variabel kontrol penelitian.

Jenis Variabel	**Nama Variabel**	**Definisi Operasional**
Variabel Bebas	Posisi Jawaban	Dua urutan penempatan jawaban di dalam *prompt*, yaitu urutan standar A–B (jawaban pertama di posisi A, jawaban kedua di posisi B) dan urutan terbalik B–A (jawaban kedua di posisi A, jawaban pertama di posisi B).
	Variasi *Prompt*	Tiga variasi instruksi evaluasi berbahasa Indonesia yang bermakna sama dengan pilihan jawaban biner (`A` atau `B`), terdiri atas *baseline* perbandingan menyeluruh (P1), multi-kriteria (P2), dan mitigasi bias (P3).
Variabel Terikat	Kesepakatan terhadap *Human Preference*	Tingkat kecocokan keputusan valid model terhadap label preferensi manusia yang diukur melalui *Accuracy* dan koefisien Cohen's kappa (κ).
	Konsistensi Posisi Jawaban	Konsistensi keputusan terhadap pertukaran urutan A–B dan B–A serta arah kecenderungan posisi, diukur melalui *Position Consistency*, *Preference Flip Rate*, dan *First-Position Preference Rate*.
	Konsistensi Variasi *Prompt*	Konsistensi keputusan lintas variasi P1, P2, dan P3 pada posisi jawaban yang sama, diukur melalui *Prompt Consistency* tiga arah dan *Prompt Flip Rate* antarpasangan *prompt*.
Variabel Kontrol	Model dan Kuantisasi	Model tunggal `Qwen/Qwen3-32B` dengan kuantisasi 8-bit (`int8`) dan tipe data *Float16* [24].
	Struktur Pesan dan Dekoding	Pesan sistem (*system prompt*) serta struktur *chat template* Qwen3 dalam mode *non-thinking* yang seragam, dekoding *greedy* deterministik (`do_sample=False`), dan batas maksimum 10 token keluaran baru.
	Data Pengujian	519 sampel pasangan jawaban unik dari dataset IndoPref yang digunakan secara seragam pada seluruh kondisi pengujian.

Tabel 3.2 menunjukkan bahwa pengujian disusun dengan prinsip pengubahan satu faktor dalam satu waktu (*one factor at a time*). Penggunaan dekoding *greedy* deterministik tanpa *sampling* acak (`do_sample=False`) bertujuan menghilangkan variasi keluaran antar-inferensi (*decoding noise*) [5][9]. Dengan pengaturan variabel kontrol tersebut, perbandingan antara urutan A–B dan B–A pada *prompt* yang sama digunakan untuk menguji pengaruh posisi jawaban secara terpisah, sedangkan perbandingan antara variasi P1, P2, dan P3 pada posisi jawaban yang sama (urutan standar A–B) digunakan untuk menguji pengaruh variasi *prompt*.

Perhitungan ketujuh metrik pada variabel terikat mengacu pada Persamaan (2.1) sampai dengan Persamaan (2.7) pada Subbab 2.2. Seluruh persamaan tersebut diterapkan pada keputusan biner yang valid (`A` atau `B`), sedangkan keluaran yang tidak memuat pilihan valid dipisahkan dan dicatat proporsinya melalui *invalid rate* [10]. Metrik *accuracy* dan Cohen's κ dihitung baik pada kondisi acuan satu urutan (P1 urutan A–B) maupun pada gabungan dua urutan (A–B dan B–A) untuk setiap variasi *prompt* serta dirinci per domain topik. Selain nilai utama metrik, perhitungan Cohen's κ dilengkapi rentang kepercayaan (*confidence interval*) 95% menggunakan metode *non-parametric percentile bootstrap* sebanyak 500 iterasi pengambilan sampel ulang dengan pengembalian (*resampling with replacement*, persentil ke-2,5 dan ke-97,5) [25], sedangkan nilai *accuracy* dilengkapi rentang kepercayaan normal (*Wald* 95% CI) sebesar $\hat{p} \pm 1{,}96\sqrt{\hat{p}(1-\hat{p})/n}$.

Untuk menguji signifikansi ketidakseimbangan arah perubahan keputusan antara urutan A–B dan B–A, digunakan uji berpasangan McNemar dengan koreksi kontinuitas [25] sebagaimana dituliskan pada Persamaan (3.1):

$$\chi^2 = \frac{(|b-c|-1)^2}{b+c} \tag{3.1}$$

dengan b menyatakan jumlah pasangan berbeda (*discordant pairs*) yang memilih jawaban pertama pada urutan A–B namun berbalik memilih jawaban kedua pada urutan B–A, dan c menyatakan jumlah pasangan berbeda yang memilih jawaban kedua pada urutan A–B namun berbalik memilih jawaban pertama pada urutan B–A.

Persamaan (3.1) menguji apakah perubahan keputusan akibat pertukaran urutan terjadi secara seimbang ke kedua arah ($p_b = p_c$) berdasarkan distribusi chi-kuadrat (χ^2) dengan derajat kebebasan df $= 1$ dan taraf signifikansi $\alpha = 0{,}05$. Nilai b menunjukkan jumlah sampel tidak konsisten yang memilih jawaban pada posisi pertama di kedua urutan (*primacy bias*), sedangkan nilai c menunjukkan jumlah sampel tidak konsisten yang memilih jawaban pada posisi kedua di kedua urutan (*recency bias*). Apabila nilai $p < 0{,}05$ (atau $\chi^2 \geq 3{,}841$), kondisi perubahan yang seimbang ($p_b = p_c$) tidak terpenuhi, yang menandakan adanya kecenderungan arah posisi yang signifikan secara statistik antara urutan A–B dan B–A.

3.2.2. Bahan Penelitian

Bahan penelitian yang digunakan adalah data sekunder dari dataset terbuka IndoPref (*A Multi-Domain Pairwise Preference Dataset for Indonesian*) yang dikembangkan oleh Wiyono dkk. [14] di bawah lisensi CC BY 4.0 pada repositori Hugging Face (`davidanugraha/IndoPref`). Dataset ini memuat 4.099 perbandingan prefe-

rensi berpasangan yang disusun dari 522 instruksi berbahasa Indonesia dan dinilai langsung oleh anotator berbahasa Indonesia lintas 10 domain topik atas respons lima model bahasa *instruction-tuned*, dengan tingkat kesepakatan antar-anotator Krippendorff's $\alpha = 0{,}891$ [14]. Sesuai batasan penelitian, label preferensi manusia pada IndoPref digunakan langsung sebagai *reference human preference* tanpa proses anotasi baru.

Struktur data IndoPref yang digunakan sebagai bahan penelitian mencakup enam atribut, yaitu kode pengenal instruksi asal (`original_id`), kategori domain topik (`domain`), teks instruksi masukan berbahasa Indonesia (`input`), teks jawaban pertama (`response_1`), teks jawaban kedua (`response_2`), serta skor hasil penilaian manusia (`actual_score`) yang menentukan jawaban yang lebih baik. Di dalam 4.099 baris perbandingan berpasangan pada dataset tersebut, terdapat 519 kode instruksi unik (`original_id`) lintas 10 domain topik karena satu instruksi yang sama dipasangkan berulang kali untuk berbagai kombinasi model penjawab. Penelitian ini menggunakan satu pasangan respons untuk setiap kode instruksi asal sehingga bahan data pengujian berjumlah 519 sampel unik dengan sebaran per domain topik sebagaimana disajikan pada Tabel 3.3.

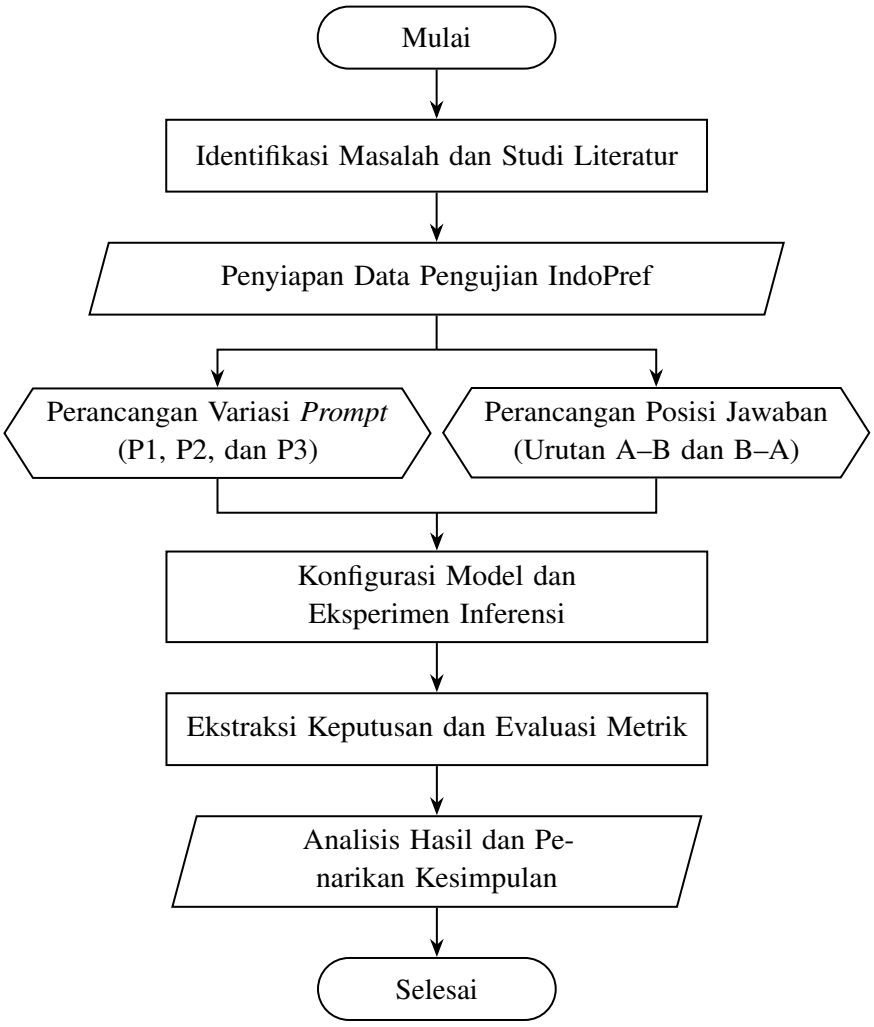
Tabel 3.3: Distribusi bahan data pengujian IndoPref pada sepuluh domain topik.

No.	Domain Topik	Jumlah Sampel	Persentase (%)
1	*Brainstorming*	70	13,49
2	*Translation*	56	10,79
3	*Logic*	53	10,21
4	*Summarization*	50	9,63
5	*Analysis*	50	9,63
6	*Open Question*	50	9,63
7	*Coding*	50	9,63
8	*Math*	49	9,44
9	*Safety*	46	8,86
10	*Creative Writing*	45	8,67
Total		**519**	**100,00**

Berdasarkan Tabel 3.3, ke-519 sampel bahan pengujian tersebar di sepuluh domain topik dengan jumlah sampel berkisar antara 45 sampel pada *Creative Writing* (8,67%) hingga 70 sampel pada *Brainstorming* (13,49%), dengan selisih 0,02% akibat pembulatan dua angka desimal pada tiap baris. Sepuluh domain tersebut meliputi tugas penulisan terbuka dan kreatif, pemahaman serta penerjemahan teks, penalaran terstruktur (*Logic*, *Math*, dan *Coding*), hingga penilaian keamanan respons (*Safety*).

3.3. Diagram Alir Penelitian

Tahapan penelitian dirancang secara sistematis mulai dari identifikasi masalah dan studi literatur hingga analisis hasil serta penarikan kesimpulan. Alur pelaksanaan penelitian secara keseluruhan disajikan dalam bentuk diagram alir pada Gambar 3.1.



Gambar 3.1: Diagram alir penelitian.

Gambar 3.1 memuat enam tahapan pelaksanaan penelitian yang menjadi acuan penyajian hasil pada Subbab 4.1. Penjelasan mengenai masing-masing tahapan pada diagram alir tersebut adalah sebagai berikut:

1. **Identifikasi Masalah dan Studi Literatur**

   Penelitian diawali dengan mengidentifikasi permasalahan reliabilitas *LLM-as-a-Judge* dalam evaluasi berpasangan, khususnya ketidakkonsistenan keputusan saat urutan posisi jawaban ditukar (*position bias*) [1][5], kepekaan terhadap variasi kalimat instruksi (*prompt sensitivity*) [6][7], perlunya koreksi metrik

kesepakatan terhadap peluang kebetulan [9][10], serta masih terbatasnya pengujian reliabilitas penilai otomatis pada teks asli Bahasa Indonesia [12][14]. Berdasarkan kajian literatur tersebut, disusun rumusan masalah, batasan penelitian, hipotesis penelitian, serta metrik evaluasi yang digunakan dalam pengujian.

2. **Penyiapan Data Pengujian IndoPref**

   Pada tahap kedua, disusun prosedur prapemrosesan terhadap dataset sekunder IndoPref sebelum digunakan dalam eksperimen. Prosedur ini meliputi pengunduhan data dari repositori sumber, pemeriksaan kelengkapan nilai pada keenam atribut (`original_id`, `domain`, `input`, `response_1`, `response_2`, dan `actual_score`) untuk memastikan tidak terdapat nilai kosong (*null*) atau string kosong, serta penyaringan data duplikat dengan mengambil baris pertama pada setiap kode instruksi asal (`original_id`). Pada setiap sampel unik, teks `response_1` ditetapkan sebagai Jawaban Pertama dan `response_2` sebagai Jawaban Kedua, sedangkan nilai `'Assistant A'` pada atribut `actual_score` dipetakan menjadi label acuan `A` (Jawaban Pertama) dan nilai `'Assistant B'` dipetakan menjadi label acuan `B` (Jawaban Kedua).

3. **Perancangan Variasi *Prompt* dan Posisi Jawaban**

   Pada tahap ketiga, dilakukan perancangan dua faktor perlakuan eksperimen secara paralel sebagaimana ditunjukkan oleh dua cabang pada Gambar 3.1, yaitu perancangan variasi *prompt* dan perancangan posisi jawaban. Untuk cabang pertama, disusun satu pesan sistem (*system prompt*) yang seragam dan tiga variasi *user prompt* berbahasa Indonesia yang bermakna sama (P1, P2, dan P3) sebagaimana disajikan pada Tabel 3.4.

Tabel 3.4: Rancangan *system prompt* dan variasi *user prompt* evaluasi.

Komponen	**Pendekatan**	**Rincian Teks *Prompt***
System Prompt	Penetapan peran penilai objektif (P1, P2, dan P3)	`Anda adalah evaluator AI yang objektif. Anda tidak memiliki bias posisi. Jawab HANYA dengan pilihan kandidat (A atau B).`

Variasi P1 (*User Prompt*)	*Baseline* perbandingan menyeluruh	`### TUGAS`
		`Bandingkan dua respons AI di bawah ini untuk instruksi yang sama. Pilih mana yang secara keseluruhan lebih baik.`
		`### INSTRUKSI`
		`{input_text}`
		`### RESPONS A`
		`{resp_A}`
		`### RESPONS B`
		`{resp_B}`
		`### FORMAT JAWABAN`
		`Keluarkan HANYA satu huruf: A atau B. Dilarang menulis alasan atau teks lain.`

Variasi P2 (*User Prompt*)	Rubrik multi-kriteria eksplisit	`### TUGAS`
		`Nilai dua respons AI berikut berdasarkan: Akurasi (kebenaran), Relevansi (menjawab instruksi), dan Kejelasan (tidak bertele-tele).`
		`### INSTRUKSI`
		`{input_text}`
		`### RESPONS A`
		`{resp_A}`
		`### RESPONS B`
		`{resp_B}`
		`### FORMAT JAWABAN`
		`Berdasarkan kriteria di atas, keluarkan HANYA satu huruf: A atau B. Dilarang memberikan penjelasan.`

Variasi P3 (*User Prompt*)	Aturan ketat mitigasi bias	`### TUGAS`
		`Tentukan respons terbaik untuk instruksi di bawah ini.`
		`### INSTRUKSI`
		`{input_text}`
		`### RESPONS A`
		`{resp_A}`
		`### RESPONS B`
		`{resp_B}`
		`### ATURAN KETAT`
		`- Abaikan urutan kemunculan respons (jangan bias posisi).`
		`- Abaikan panjang respons (jangan bias verbosity).`
		`- FORMAT JAWABAN WAJIB: Keluarkan hanya karakter A atau B.`

Berdasarkan Tabel 3.4, bagian *placeholder* `{input_text}`, `{resp_A}`, dan `{resp_B}` pada *template* diisi dengan teks instruksi masukan serta pasangan jawaban untuk posisi pertama dan posisi kedua. Ketiga variasi *prompt* tetap memberikan tugas pemilihan respons terbaik dengan batasan keluaran satu huruf (`A` atau `B`) tanpa penalaran *Chain-of-Thought*, namun memiliki perbedaan pada cara penyampaian pedoman penilaian: P1 meminta perbandingan menyeluruh secara langsung [1], P2 merinci kriteria penilaian menjadi akurasi, relevansi, dan kejelasan [2][4], sedangkan P3 menambahkan aturan eksplisit untuk mengabaikan urutan kemunculan dan panjang respons (*verbosity bias*) [1][8].

Untuk faktor kedua, disusun skema pertukaran posisi jawaban guna menguji setiap variasi *prompt* pada dua urutan posisi jawaban. Label bagian `### RESPONS A` tetap diletakkan pada posisi pertama dan `### RESPONS B` pada posisi kedua, sedangkan teks jawaban yang dimasukkan ke kedua posisi tersebut dipertukarkan sebagaimana dirinci pada Tabel 3.5.

Tabel 3.5: Skema penempatan posisi jawaban pada urutan A–B dan B–A.

Urutan Posisi	**Isi Posisi Pertama** (`### RESPONS A`)	**Isi Posisi Kedua** (`### RESPONS B`)	**Label Acuan pada Posisi**	**Pemetaan Keputusan ke Jawaban Asli**
A–B (Standar)	Jawaban Pertama	Jawaban Kedua	Tetap sesuai urutan jawaban asli	Keputusan `A` → Jawaban Pertama; Keputusan `B` → Jawaban Kedua
B–A (Terbalik)	Jawaban Kedua	Jawaban Pertama	Dibalik mengikuti pertukaran posisi	Keputusan `A` → Jawaban Kedua; Keputusan `B` → Jawaban Pertama

Tabel 3.5 membedakan antara label posisi yang dipilih model di dalam *prompt* (`A` untuk posisi pertama atau `B` untuk posisi kedua) dan jawaban asli yang dipilih. Pada urutan B–A, pilihan `A` mengacu pada teks di posisi pertama yang berisi Jawaban Kedua, sehingga keputusan tersebut dipetakan kembali menjadi Jawaban Kedua. Dengan pemetaan ini, konsistensi keputusan antara urutan A–B dan B–A diukur berdasarkan kesamaan jawaban asli yang dipilih, sedangkan kecenderungan model terhadap urutan posisi diukur dari proporsi pemilihan posisi pertama (`A`) pada kedua urutan (*first-position preference rate*).

4. **Konfigurasi Model dan Eksperimen Inferensi**

   Pada tahap keempat, ditetapkan konfigurasi pemuatan model `Qwen/Qwen3-32B` beserta *tokenizer* bawaannya pada memori GPU menggunakan kuantisasi

8-bit (`int8`) dan tipe data komputasi *Float16* [24]. Pasangan *system prompt* dan *user prompt* pada setiap skenario kemudian disusun mengikuti format *chat template* Qwen3 dalam mode *non-thinking*. Kombinasi dari 519 sampel data pengujian, tiga variasi *prompt* (P1, P2, dan P3), serta dua urutan posisi jawaban (A–B dan B–A) menghasilkan rancangan pengujian berjumlah $519 \times 3 \times 2 = 3.114$ skenario inferensi. Setiap skenario dijalankan menggunakan dekoding *greedy* deterministik (`do_sample=False`) dengan batas maksimum 10 token keluaran baru serta dilengkapi penyimpanan bertahap (*checkpointing*) dalam format JSONL.

5. **Ekstraksi Keputusan dan Evaluasi Metrik**

   Tahap kelima mencakup proses ekstraksi keputusan dari teks keluaran mentah pada setiap skenario inferensi menggunakan pola *regular expression* (*word-boundary regex*) untuk mengekstrak jawaban satu huruf (`A` atau `B`). Apabila keluaran model tidak memuat salah satu huruf tersebut secara jelas, skenario ditandai sebagai *invalid*, dihitung proporsinya ke dalam *invalid rate*, dan dipisahkan tanpa dimasukkan ke salah satu pilihan jawaban [10]. Keputusan biner yang valid selanjutnya dipetakan kembali ke jawaban aslinya sesuai Tabel 3.5 untuk menghitung metrik kesepakatan terhadap preferensi manusia (*accuracy* dan Cohen's κ), konsistensi serta arah bias posisi (*position consistency*, *preference flip rate*, dan *first-position preference rate*), serta konsistensi lintas variasi *prompt* (*prompt consistency* dan *prompt flip rate*).

6. **Analisis Hasil dan Penarikan Kesimpulan**

   Pada tahap akhir, dilakukan analisis terhadap nilai ketujuh metrik reliabilitas, rincian kesepakatan per domain topik, rentang kepercayaan 95%, serta hasil uji McNemar pada Persamaan (3.1). Pengujian Hipotesis 1 dilakukan dengan membandingkan konsistensi dan kesepakatan keputusan antara posisi jawaban A–B dan B–A, sedangkan pengujian Hipotesis 2 dilakukan dengan membandingkan perubahan keputusan serta kesepakatan lintas variasi *prompt* P1, P2, dan P3. Seluruh temuan tersebut kemudian dirangkum menjadi kesimpulan untuk menjawab ketiga rumusan masalah penelitian.

BAB IV

HASIL DAN PEMBAHASAN

4.1. Hasil

Uraikan secara sistematis hasil penelitian atau pengujian yang telah dilakukan.

4.2. Pembahasan

Berikan analisis dan interpretasi mendalam terhadap hasil yang telah diperoleh, serta bandingkan dengan hipotesis atau teori yang ada.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berisi poin-poin kesimpulan yang menjawab rumusan masalah secara langsung.

5.2. Saran

Berisi masukan untuk pengembangan atau perbaikan penelitian selanjutnya berdasarkan keterbatasan penelitian ini.

DAFTAR PUSTAKA

[1] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," Dec. 2023.

[2] J. Gu, X. Jiang, Z. Shi, H. Tan, X. Zhai, C. Xu, W. Li, Y. Shen, S. Ma, H. Liu, S. Wang, K. Zhang, Y. Wang, W. Gao, L. Ni, and J. Guo, "A Survey on LLM-as-a-Judge," Oct. 2025.

[3] A. Bavaresco, R. Bernardi, L. Bertolazzi, D. Elliott, R. Fernández, A. Gatt, E. Ghaleb, M. Giulianelli, M. Hanna, A. Koller, A. F. T. Martins, P. Mondorf, V. Neplenbroek, S. Pezzelle, B. Plank, D. Schlangen, A. Suglia, A. K. Surikuchi, E. Takmaz, and A. Testoni, "LLMs instead of Human Judges? A Large Scale Empirical Study across 20 NLP Evaluation Tasks," June 2025.

[4] H. Li, Q. Dong, J. Chen, H. Su, Y. Zhou, Q. Ai, Z. Ye, and Y. Liu, "LLMs-as-Judges: A Comprehensive Survey on LLM-based Evaluation Methods," Dec. 2024.

[5] L. Shi, C. Ma, W. Liang, X. Diao, W. Ma, and S. Vosoughi, "Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge," in *Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics*, pp. 292–314, Association for Computational Linguistics, Dec. 2025.

[6] H. Wei, S. He, T. Xia, F. Liu, A. Wong, J. Lin, and M. Han, "Systematic Evaluation of LLM-as-a-Judge in LLM Alignment Tasks: Explainable Metrics and Diverse Prompt Templates," Mar. 2025.

[7] R. R. Bellibatlu, E. Raff, and W. Zhang, "JudgeSense: A Benchmark for Prompt Sensitivity in LLM-as-a-Judge Systems," Sept. 2026.

[8] C. Anghel, A. A. Anghel, E. Pecheanu, A. Cocu, A. Istrate, and C. A. Andrei, "Diagnosing Bias and Instability in LLM Evaluation: A Scalable Pairwise Meta-Evaluator," *Information*, vol. 16, p. 652, July 2025.

[9] J. D. Norman, M. U. Rivera, and D. A. Hughes, "Reliability without Validity: A Systematic, Large-Scale Evaluation of LLM-as-a-Judge Models Across Agreement, Consistency, and Bias," June 2026.

[10] D. Rao and C. Callison-Burch, "Agreement Metrics for LLM-as-Judge Evaluation: What to Report and Why," July 2026.

[11] M. Xu, X. Tan, J. Wu, and D. Zhou, "A Judge-Aware Ranking Framework for Evaluating Large Language Models without Ground Truth," June 2026.

[12] A. S. Doğruöz, X. Liao, V. Blaschke, J. Prange, S. Li, and D. I. Adelani, "Challenges and Recommendations for LLM-as-a-Judge in Multilingual Settings and for Low-Resource Languages," Sept. 2026.

[13] X. Fu and W. Liu, "How Reliable is Multilingual LLM-as-a-Judge?," May 2025.

[14] V. R. Wiyono, D. Anugraha, A. Purwarianti, and G. I. Winata, "IndoPref: A Multi-Domain Pairwise Preference Dataset for Indonesian," Nov. 2025.

[15] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, C. Zheng, D. Liu, F. Zhou, F. Huang, F. Hu, H. Ge, H. Wei, H. Lin, J. Tang, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Zhou, J. Lin, K. Dang, K. Bao, K. Yang, L. Yu, L. Deng, M. Li, M. Xue, M. Li, P. Zhang, P. Wang, Q. Zhu, R. Men, R. Gao, S. Liu, S. Luo, T. Li, T. Tang, W. Yin, X. Ren, X. Wang, X. Zhang, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Zhang, Y. Wan, Y. Liu, Z. Wang, Z. Cui, Z. Zhang, Z. Zhou, and Z. Qiu, "Qwen3 Technical Report," May 2025.

[16] Z. Li, C. Wang, P. Ma, D. Wu, S. Wang, C. Gao, and Y. Liu, "Split and Merge: Aligning Position Biases in LLM-based Evaluators," in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, (Miami, Florida, USA), pp. 11084–11108, Association for Computational Linguistics, 2024.

[17] A. Yagubyan, "The Coin Flip Judge? Reliability and Bias in LLM-as-a-Judge Evaluation," Apr. 2026.

[18] S. Tan, S. Zhuang, K. Montgomery, W. Y. Tang, A. Cuadron, C. Wang, R. A. Popa, and I. Stoica, "JudgeBench: A Benchmark for Evaluating LLM-based Judges," Apr. 2025.

[19] A. S. Thakur, K. Choudhary, V. S. Ramayapally, S. Vaidyanathan, and D. Hupkes, "Judging the Judges: Evaluating Alignment and Vulnerabilities in LLMs-as-Judges," Aug. 2025.

[20] G. Son, D. Yoon, J. Suk, J. Aula-Blasco, M. Aslan, V. T. Kim, S. B. Islam, J. Prats-Cristià, L. Tormo-Bañuelos, and S. Kim, "MM-Eval: A Multilingual Meta-Evaluation Benchmark for LLM-as-a-Judge and Reward Models," Mar. 2025.

[21] X. Zhou, Z. Luo, Y. Gao, Q. Chen, X. Hu, Y. Zhao, and R. Liu, "Fairness or Fluency? An Investigation into Language Bias of Pairwise LLM-as-a-Judge," Jan. 2026.

[22] S. Yin, "Does the Judge Prefer English? Evaluating Language-Switching Invariance in LLM-as-a-Judge," June 2026.

[23] J. Pombal, D. Yoon, P. Fernandes, I. Wu, S. Kim, R. Rei, G. Neubig, and A. F. T. Martins, "M-Prometheus: A Suite of Open Multilingual LLM Judges," Oct. 2025.

[24] T. Dettmers, A. Pagnoni, A. Holtzman, and L. Zettlemoyer, "QLoRA: Efficient Finetuning of Quantized LLMs," May 2023.

[25] S. K. Chandrahas, "Evalci: A Python Library for Statistically Rigorous Comparison of Language Model Evaluations," July 2026.

Lampiran A: Daftar Pustaka dan Publikasi

Lampiran B: Source Code Program

Lampiran C: Panduan Penggunaan Aplikasi