Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Kandidat dalam Bahasa Indonesia

Tugas Akhir

diajukan untuk memenuhi salah satu syarat memperoleh gelar sarjana
pada Program Studi Informatika
Direktorat Kampus Purwokerto
Universitas Telkom

2311102293
Rozhak



Program Studi Sarjana Informatika
Direktorat Kampus Purwokerto
Universitas Telkom
Purwokerto
2026

LEMBAR PENGESAHAN

Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Kandidat dalam Bahasa Indonesia

Reliability Analysis of LLM-as-a-Judge under Prompt and Candidate Position Variations in Indonesian

2311102293
Rozhak

Tugas akhir ini telah diterima dan disahkan untuk memenuhi sebagai syarat
memperoleh gelar pada Program Studi Sarjana Informatika
Direktorat Kampus Purwokerto
Universitas Telkom

Purwokerto, 1 Mei 2026
Menyetujui

Pembimbing I,	Pembimbing II,
Andi Prademon Yunus, S.T., M.Sc.Eng., Ph.D	Nisrina Hanifa Setiono, S.Kom., M.Cs
NIP: 23930008	NIP: 25010030
Penguji I,	Penguji II,
(Nama Lengkap Penguji 1 dan Gelar)	(Nama Lengkap Penguji 2 dan Gelar)
NIP: 12345	NIP: 12345

Ketua Program Studi Sarjana Informatika,

Aditya Dwi Putro W, S.Kom., M.Kom
NIP: 17930003

LEMBAR ORISINALITAS

Dengan ini saya, Rozhak, menyatakan sesungguhnya bahwa Tugas Akhir saya dengan judul Analisis Reliabilitas LLM-as-a-Judge pada Variasi Prompt dan Posisi Kandidat dalam Bahasa Indonesia beserta dengan seluruh isinya merupakan hasil karya saya sendiri, dengan tidak melakukan penjiplakan yang tidak sesuai dengan etika keilmuan yang berlaku dengan masyarakat keilmuan, serta produk dari tugas akhir ini bukan merupakan hasil dari *Generative AI*. Saya siap menanggung risiko/sanksi yang diberikan jika di kemudian hari ditemukan pelanggaran terhadap etika keilmuan dalam Laporan Tugas Akhir, atau jika ada klaim dari pihak lain terhadap keaslian karya.

Purwokerto, 1 Mei 2026
Yang menyatakan

Materai 10.000

Rozhak
NIM: 2311102293

ABSTRAK

Abstrak ditulis dengan format font Time New Roman size 11 spasi 1 dalam bahasa Indonesia. Isinya merupakan uraian singkat tetapi lengkap mengenai permasalahan, tujuan, metode penelitian, hasil, dan kesimpulan. Tujuan penelitian disarikan dari tujuan penelitian pada pendahuluan, metode penelitian disarikan dari proses penelitian, dan hasil penelitian ditarik dari kesimpulan dengan nilai hasil secara kualitatif dan kuantitatif. Abstrak atau abstract terdiri atas satu alinea dan satu spasi maksimal 200 kata. Tidak boleh ada sitasi pada abstrak. Pada abstrak tidak menggunakan penamaan, simbol atau istilah yang teknis, misalnya minsup untuk menyatakan nilai support minimal.

Kata Kunci: merupakan kata-kata kunci yang menjelaskan isi tulisan, biasanya dapat diambil dari judul dan abstrak. Maksimal enam buah dan ditulis dengan huruf kecil. Contoh: abstrak, bahasa Indonesia, kualitatif, kuantitatif

ABSTRACT

The abstract should state briefly the general aspects of the subject and the main conclusions. The length of abstract should bo no more than 200 words and should be typed be with 11 pts. Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do euismod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Keywords: keyword should be chosen that they best describe the contents of the paper and should be typed in lower-case, except abbreviation. Keyword should be no more than 6 words.

KATA PENGANTAR

Kata pengantar laporan tugas akhir ini berisi ucapan syukur, penjelasan singkat tentang tujuan dan latar belakang penulisan, serta ucapan terima kasih kepada pihak-pihak yang telah membantu proses penyusunan tugas akhir.

1. Ucapan syukur kepada Tuhan Yang Maha Esa.
2. Ucapan terimakasih kepada Rektor Universitas Telkom.
3. Ucapan terimakasih kepada Direktur Universitas Telkom Direktorat Kampus Purwokerto.
4. Ucapan terimakasih kepada Ketua Program Studi.
5. Ucapan terimakasih kepada Dosen Pembimbing.
6. Ucapan terima kasih kepada individu maupun lembaga yang memberikan bantuan, bimbingan dan dukungan yang relevan.

Purwokerto, 1 Mei 2026

Rozhak

DAFTAR ISI

LEMBAR PENGESAHAN ii

LEMBAR ORISINALITAS iii

ABSTRAK iv

ABSTRACT v

KATA PENGANTAR vi

DAFTAR ISI vii

DAFTAR GAMBAR ix

DAFTAR TABEL x

DAFTAR LAMPIRAN xi

BAB I PENDAHULUAN 1

1.1. Latar Belakang 1
1.2. Rumusan Masalah 3
1.3. Tujuan Penelitian 4
1.4. Manfaat Penelitian 4
1.5. Batasan Masalah 4
1.6. Hipotesis Penelitian 5
1.7. Jadwal Penelitian 5

BAB II LANDASAN TEORI 7

2.1. Tinjauan Pustaka 7
2.2. Landasan Teori 14
2.2.1. Large Language Models 14
2.2.2. LLM-as-a-Judge 14
2.2.3. Reliabilitas LLM Judge 15
2.2.4. Position Bias 16
2.2.5. Prompt Sensitivity 17
2.2.6. Evaluasi LLM Bahasa Indonesia 18

2.2.7. Sintesis dan Research Gap 18

BAB III METODE PENELITIAN 20

3.1. Subjek dan Objek Penelitian 20
3.2. Alat dan Bahan Penelitian 20
3.2.1. Alat Penelitian 20
3.2.2. Bahan Penelitian 20
3.2.3. Diagram Alir Penelitian 20

BAB IV HASIL DAN PEMBAHASAN 22

4.1. Hasil 22
4.2. Pembahasan 22
4.3. Implikasi Tugas Akhir (Khusus SI) 22

BAB V KESIMPULAN DAN SARAN 23

5.1. Kesimpulan 23
5.2. Saran 23

DAFTAR PUSTAKA 24

LAMPIRAN 27

DAFTAR GAMBAR

3.1 Contoh Diagram Alir Penelitian 21

DAFTAR TABEL

1.1 Jadwal penelitian tugas akhir. 6

2.1 Ringkasan penelitian terdahulu. 7

DAFTAR LAMPIRAN

1
simulasi algoritma.21

Lampiran A: Daftar Pustaka dan Publikasi **27**

Lampiran B: Source Code Program **28**

Lampiran C: Panduan Penggunaan Aplikasi **29**

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perkembangan *large language model* (LLM) mendorong pemanfaatan model bahasa generatif pada berbagai tugas pemrosesan bahasa alami [1][2]. Penilaian kualitas respons yang dihasilkan LLM umumnya memerlukan preferensi manusia (*human preference*) sebagai acuan, tetapi evaluasi manual membutuhkan biaya dan waktu yang besar ketika jumlah data pengujian meningkat [1][3]. Kebutuhan tersebut melahirkan paradigma *LLM-as-a-Judge*, yaitu penggunaan LLM sebagai penilai otomatis, salah satunya melalui perbandingan berpasangan (*pairwise comparison*) untuk memilih respons yang lebih baik di antara dua kandidat [1][4]. Pada pengujian berbahasa Inggris seperti MT-Bench dan Chatbot Arena, model penilai seperti GPT-4 dilaporkan mampu mencapai kesepakatan di atas 80% terhadap preferensi manusia pada pasangan keputusan non-seri [1].

Meskipun demikian, penerapan *LLM-as-a-Judge* menghadapi masalah reliabilitas karena keputusan model belum tentu konsisten ketika urutan posisi kandidat ditukar (*position bias*) [1][5] maupun ketika kalimat instruksi penilaian diubah (*prompt sensitivity*) [6][7]. Hal ini terjadi karena model penilai peka terhadap urutan penempatan kandidat di dalam konteks masukan, terutama saat selisih kualitas antarkandidat berdekatan [4][5], serta terhadap cara perumusan instruksi dan kriteria penilaian di dalam *prompt* [6][7]. Ketidakstabilan tersebut terlihat pada pengujian MT-Bench dengan *prompt* bawaan, ketika pertukaran urutan kandidat dari A–B menjadi B–A pada pasangan respons yang setara hanya menyisakan konsistensi keputusan sebesar 23,8%–65,0% [1], serta pada perbandingan berpasangan terbuka yang mengalami pembalikan putusan (*preference flip*) sebesar 48,4% saat urutan respons dibalik [8]. Perubahan redaksi instruksi yang setara secara semantik (*semantically equivalent*) juga menurunkan konsistensi putusan model melampaui variasi dekoding internal (*decoding noise*) [7], sedangkan perbedaan *template prompt* dapat menggeser tingkat kesepakatan dengan manusia serta membalik arah kecenderungan posisi dari kandidat pertama ke kandidat kedua [6]. Selain itu, pengukuran kesepakatan yang hanya mengandalkan persentase kecocokan mentah (*exact match*) melampaui

nilai Cohen's kappa sebesar 33,8 hingga 41,3 poin persentase pada MT-Bench karena belum memperhitungkan peluang acak [9], serta dapat memberikan gambaran performa yang menyesatkan ketika distribusi putusan timpang [10]. Apabila reliabilitas penilai tidak diuji terhadap perubahan posisi maupun variasi *prompt*, keputusan pemilihan kandidat dapat berubah hanya karena pergeseran urutan penyajian [5][9] atau formulasi *prompt* [6][7], serta menghasilkan pemeringkatan kualitas model yang bias pada sistem evaluasi yang lebih luas ketika penilaian dari *judge* yang kurang andal diagregasikan secara langsung [11].

Permasalahan reliabilitas tersebut semakin relevan untuk dikaji pada Bahasa Indonesia. Dari 650 publikasi *LLM-as-a-Judge* di repositori ACL Anthology, hanya 33 penelitian (5,1%) yang mengkaji konteks multibahasa atau bahasa bersumber daya rendah, dengan validasi keandalan penilai yang kerap dilewatkan pada bahasa sasaran atau hanya bertumpu pada satu model *judge* [12]. Pengujian pada data paralel lintas 25 bahasa juga menunjukkan bahwa konsistensi penilaian model lintas bahasa masih rendah dengan rata-rata Fleiss' kappa sekitar 0,3 [13]. Untuk Bahasa Indonesia, telah tersedia dataset preferensi berpasangan IndoPref yang disusun dari penutur asli dan memuat 522 *prompt* serta 4.099 pasangan preferensi lintas 10 domain [14]. Namun, evaluasi pada dataset IndoPref menunjukkan bahwa akurasi *judge* tertinggi baru mencapai 74,34% (pada Gemini 2.5 Pro), dan penerjemahan *prompt* instruksi evaluasi dari bahasa Inggris ke Bahasa Indonesia dapat menurunkan akurasi model hingga 6,39 poin persentase (dari 69,84% menjadi 63,45% pada GPT-4.1) [14].

Beberapa pendekatan dapat digunakan untuk mengevaluasi dan menangani masalah ketidakstabilan *LLM-as-a-Judge* tersebut, antara lain pengujian kecocokan satu arah terhadap label referensi manusia tanpa menguji pembalikan urutan kandidat [3][14], mitigasi dua urutan yang menetapkan keputusan tidak konsisten (*inconsistent*) antara A–B dan B–A sebagai hasil seri (*tie*) [1][4], penggabungan suara dari beberapa model penilai (*ensemble judge*) [13], serta pengujian reliabilitas yang memeriksa pertukaran posisi kandidat [5][8] dan variasi formulasi *prompt* [6][7]. Sejauh ini, penelitian yang menguji *position bias* [1][5], sensitivitas formulasi *prompt* [6][7], serta koreksi metrik kesepakatan terhadap peluang [9][10] umumnya dilakukan pada korpus berbahasa Inggris, sedangkan penelitian pada dataset IndoPref [14] baru mengevaluasi akurasi satu arah tanpa memisahkan pengaruh posisi kandidat dan variasi formulasi *prompt* berbahasa Indonesia yang setara secara semantik. Dengan demikian, penelitian khusus Bahasa Indonesia yang menggunakan *human preference* sebagai acuan serta menguji pengaruh posisi kandidat dan variasi formulasi *prompt* secara terpisah masih terbatas. Penelitian ini memilih pendekatan pengujian dengan mengubah satu faktor dalam satu waktu (*one factor at a time*),

karena pengujian satu arah tidak dapat mendeteksi pembalikan putusan, penetapan *tie* menyembunyikan proporsi *flip rate* pada pasangan kandidat, dan penggunaan *ensemble* membutuhkan inferensi dari beberapa model sekaligus tanpa memisahkan sumber ketidakkonsistenan pada model tunggal.

Penelitian ini mengusulkan evaluasi reliabilitas model sumber terbuka `Qwen/Qwen3-4B-Instruct-2507` sebagai model *judge* tunggal pada 519 sampel terstratifikasi lintas 10 domain dari dataset IndoPref [14], sehingga perubahan keputusan yang terukur tidak tercampur dengan perbedaan arsitektur antarmodel. Pengujian dijalankan pada enam kondisi kombinasi dari dua urutan posisi kandidat (kondisi A–B dan B–A) serta tiga formulasi *prompt* berbahasa Indonesia yang setara secara semantik, yaitu *prompt baseline* perbandingan holistik (P1), *prompt* multi-kriteria mencakup akurasi, relevansi, dan kejelasan (P2), serta *prompt* mitigasi bias (P3), dengan total 3.114 inferensi. Hasil inferensi tersebut dianalisis dengan membandingkan kedua kondisi posisi pada *prompt* yang sama serta membandingkan ketiga formulasi *prompt* pada urutan posisi yang sama. Dibandingkan evaluasi satu arah yang hanya melaporkan akurasi mentah pada satu urutan dan satu *prompt*, pendekatan ini memungkinkan pengukuran kesepakatan terhadap preferensi manusia menggunakan metrik *accuracy* dan Cohen's kappa [9][10], sekaligus memisahkan besaran ketidakkonsistenan akibat posisi kandidat melalui *position consistency*, *preference flip rate*, dan *first-position preference rate* [5][9] serta akibat variasi formulasi *prompt* melalui *prompt consistency* dan *prompt flip rate* yang diadaptasi dari pengujian sensitivitas *prompt* [6][7]. Berdasarkan latar belakang dan permasalahan tersebut, penelitian ini bertujuan untuk mengukur dan menganalisis tingkat konsistensi keputusan `Qwen/Qwen3-4B-Instruct-2507` sebagai *LLM-as-a-Judge* terhadap *human preference* pada respons Bahasa Indonesia dalam dataset IndoPref, serta menganalisis pengaruh perubahan posisi kandidat dan variasi formulasi *prompt* terhadap konsistensi keputusannya.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Seberapa konsisten keputusan LLM-as-a-Judge dengan *human preference* pada respons Bahasa Indonesia?
2. Bagaimana perubahan posisi kandidat (A–B dan B–A) memengaruhi konsistensi keputusan LLM-as-a-Judge?

3. Bagaimana variasi formulasi *prompt* memengaruhi konsistensi keputusan LLM-as-a-Judge?

1.3. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diidentifikasi, tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Mengukur tingkat konsistensi keputusan *LLM-as-a-Judge* terhadap *human preference* pada respons Bahasa Indonesia menggunakan metrik *accuracy* dan Cohen's kappa.

2. Menganalisis pengaruh perubahan posisi kandidat (A–B dan B–A) terhadap konsistensi keputusan *LLM-as-a-Judge* menggunakan metrik *position consistency*, *preference flip rate*, dan *first-position preference rate*.

3. Menganalisis pengaruh variasi formulasi *prompt* yang setara secara semantik terhadap konsistensi keputusan *LLM-as-a-Judge* menggunakan metrik *prompt consistency* dan *prompt flip rate*.

1.4. Manfaat Penelitian

Apabila permasalahan dalam penelitian ini dapat diselesaikan, manfaat yang diharapkan bagi pihak terkait adalah sebagai berikut:

1. **Bagi Akademisi:** Menjadi rujukan empiris dan protokol pengujian yang dapat direplikasi mengenai reliabilitas *LLM-as-a-Judge* pada evaluasi respons Bahasa Indonesia.

2. **Bagi Praktisi dan Pengembang:** Menjadi bahan pertimbangan dalam memilih formulasi *prompt* dan mengantisipasi bias posisi kandidat saat menggunakan LLM sebagai penilai otomatis.

1.5. Batasan Masalah

Untuk memperjelas ruang lingkup dan kondisi berlakunya hasil penelitian, batasan masalah dalam penelitian ini ditetapkan sebagai berikut:

1. Model *judge* yang diuji dibatasi pada satu model sumber terbuka, yaitu `Qwen/Qwen3-4B-Instruct-2507` dengan kuantisasi 4-bit pada lingkungan

Google Colab satu GPU tanpa *training* atau *fine-tuning*, sehingga temuan penelitian berlaku spesifik pada model dan konfigurasi tersebut.

2. Data pengujian menggunakan 519 sampel terstratifikasi lintas 10 domain dari dataset IndoPref dengan memanfaatkan label *reference human preference* yang tersedia tanpa perekrutan anotator baru.

3. Pengujian posisi kandidat dilakukan pada perbandingan berpasangan dua urutan, yaitu kondisi A–B (kandidat A ditampilkan pertama dan kandidat B kedua) serta kondisi B–A (kandidat B ditampilkan pertama dan kandidat A kedua).

4. Variasi *prompt* menggunakan tiga formulasi berbahasa Indonesia yang setara secara semantik, yaitu *baseline* holistik (P1), multi-kriteria (P2), dan mitigasi bias (P3).

5. Keluaran eksperimen utama dibatasi pada pilihan biner (`A` atau `B`) tanpa penalaran *Chain-of-Thought*.

1.6. Hipotesis Penelitian

Berdasarkan permasalahan yang telah diuraikan mengenai pengaruh posisi kandidat dan variasi formulasi *prompt*, hipotesis yang diajukan dalam penelitian ini adalah sebagai berikut:

1. Perubahan posisi kandidat dapat menyebabkan perubahan keputusan LLM-as-a-Judge dan menurunkan konsistensi keputusan terhadap *human preference*.

2. Variasi formulasi *prompt* yang *semantically equivalent* dapat menyebabkan perubahan keputusan LLM-as-a-Judge dan memengaruhi konsistensinya terhadap *human preference*.

1.7. Jadwal Penelitian

Jadwal pelaksanaan penelitian ini disusun selama enam bulan sebagaimana ditunjukkan pada Tabel 1.1.

Tabel 1.1: Jadwal penelitian tugas akhir.

No	Kegiatan	Bulan ke-																					
		1				2				3				4				5				6			
1	Studi Literatur																								
2	Penyiapan Data IndoPref dan Sampling																								
3	Perancangan Prompt dan Konfigurasi Uji																								
4	Pelaksanaan Eksperimen Inferensi																								
5	Analisis Reliabilitas dan Evaluasi Statistik																								
6	Penulisan Laporan Tugas Akhir																								

Tabel 1.1 menyajikan tahapan pengerjaan Tugas Akhir mulai dari studi literatur, penyiapan data, perancangan dan pelaksanaan eksperimen, analisis hasil, hingga penulisan laporan.

BAB II

LANDASAN TEORI

2.1. Tinjauan Pustaka

Tinjauan pustaka disusun untuk memetakan perkembangan penelitian tentang reliabilitas *LLM-as-a-Judge* sekaligus menegaskan posisi Tugas Akhir ini di antara penelitian yang sudah ada. Tabel 2.1 merangkum sepuluh penelitian terdahulu pada rentang tahun 2023–2026 yang dipilih karena relevan dengan tiga aspek utama penelitian ini, yaitu bias posisi kandidat, sensitivitas formulasi *prompt*, dan evaluasi pada Bahasa Indonesia atau konteks multibahasa. Setiap penelitian diuraikan berdasarkan pokok bahasan dan metodenya, kemudian dianalisis kelebihan serta keterbatasannya. Analisis tersebut menjadi dasar untuk menjelaskan perbedaan penelitian ini terhadap setiap rujukan.

Tabel 2.1: Ringkasan penelitian terdahulu.

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
1	*Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena* (2023) [1]	Penelitian ini menguji penggunaan LLM sebagai penilai dialog terbuka. GPT-4 mencapai kesepakatan $> 80\%$ dengan manusia pada putusan non-seri, tetapi konsistensi posisi *prompt* bawaan hanya 23,8%–65,0% pada pasangan respons yang setara.	*Pairwise comparison*, *single-answer*, dan *reference-guided grading* pada GPT-4, GPT-3.5, serta Claude-v1 dengan mitigasi *swap-tie*.	**Kelebihan:** Divalidasi terhadap anotator ahli dan data *crowdsourcing* berskala besar. **Kekurangan:** Berbahasa Inggris, hanya memakai kecocokan mentah, dan aturan *tie* menutupi besarnya *flip rate*.	Menguji respons Bahasa Indonesia IndoPref pada `Qwen/Qwen3-4B-Instruct-2507` dengan keluaran biner, Cohen's kappa, serta variasi *prompt*.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
2	*Split and Merge: Aligning Position Biases in LLM-based Evaluators* (2024) [15]	Penelitian ini mengkaji bias posisi pada 11.520 evaluasi pasangan MT-Bench. Konsistensi awal bervariasi (Claude2 28,28% *relation-based*; GPT-4 61,50% *likert-based* dengan $>78\%$ kasus tidak konsisten memilih posisi kedua), dan meningkat relatif 47,46% dengan PORTIA.	Metode *split-and-merge* (PORTIA) pada enam model *judge* dengan format *relation-based*, *score-based*, dan *likert-based*.	**Kelebihan:** Menunjukkan pengaruh format penilaian terhadap arah bias tanpa *fine-tuning*. **Kekurangan:** Jumlah token masukan bertambah panjang, gagal 17,13% pada tugas kode, dan khusus bahasa Inggris.	Tidak memecah teks kandidat, melainkan menguji pengaruh posisi (A–B dan B–A) serta tiga formulasi *prompt* Bahasa Indonesia.
3	*Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge* (2025) [5]	Penelitian ini menganalisis *position bias* pada >150.000 evaluasi MT-Bench dan DevBench. Stabilitas pengulangan umumnya $>0,85$ pada model *judge* yang andal sehingga menunjukkan bias bersifat sistematis, sedangkan konsistensi posisi (0,57–0,82 di MT-Bench) turun saat kualitas kandidat berdekatan.	Pertukaran urutan posisi *pairwise* dan *listwise* pada 15 *judge* memakai *repetition stability*, *position consistency*, *preference fairness*, dan regresi.	**Kelebihan:** Memisahkan bias sistematis dari variasi acak serta mengukur pengaruh selisih kualitas kandidat. **Kekurangan:** Tidak menguji variasi formulasi *prompt* dan terbatas pada bahasa Inggris.	Menggabungkan pengujian posisi kandidat dengan tiga formulasi *prompt* Bahasa Indonesia setara semantik terhadap acuan manusia IndoPref.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
4	*Diagnosing Bias and Instability in LLM Evaluation: A Scalable Pairwise Meta-Evaluator* (2025) [8]	Penelitian ini menguji 3.600 perbandingan (1.800 pasangan bolak-balik A–B dan B–A). Sebanyak 48,4% putusan berbalik saat posisi ditukar meskipun tiga *judge* bersepakat 100%, dan penambahan instruksi anti-bias hanya memberi perbaikan terbatas.	Pengujian berpasangan dua arah, perubahan kata serta parafrase, dan penambahan aturan anti-bias pada LLaMA 3:8B, OpenHermes, serta Nous-Hermes 2.	**Kelebihan:** Menunjukkan bahwa kesepakatan 100% antar-*judge* tetap dapat menyimpan bias posisi yang sama. **Kekurangan:** Hanya memakai 10 soal bahasa Inggris tanpa label acuan manusia.	Mengevaluasi 519 sampel terstratifikasi dari 10 domain Bahasa Indonesia yang memiliki label *reference human preference*.
5	*Systematic Evaluation of LLM-as-a-Judge in LLM Alignment Tasks: Explainable Metrics and Diverse Prompt Templates* (2025) [6]	Penelitian ini menguji variasi *template prompt* pada tugas peringkasan dan dialog. Akurasi dua urutan berada di bawah $0,7$ (turun hingga $< 0,2$ pada *template* yang kurang sesuai), dan pergantian *template* dapat membalik arah *position bias*.	Pertukaran urutan kandidat dengan koreksi *flipping noise* pada tiga model OpenAI memakai 8 *template* TL;DR dan 10 *template* HH-RLHF.	**Kelebihan:** Menunjukkan hubungan antara pilihan *template*, arah bias posisi, dan akurasi. **Kekurangan:** Hanya menguji model tertutup OpenAI pada data berbahasa Inggris.	Menguji model sumber terbuka `Qwen/Qwen3-4B-Instruct-2507` pada Bahasa Indonesia dengan tiga formulasi *prompt* yang setara secara semantik.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
6	*JudgeSense: A Benchmark for Prompt Sensitivity in LLM-as-a-Judge Systems* (2026) [7]	Penelitian ini mengukur sensitivitas model terhadap parafrase instruksi yang setara secara semantik. Perubahan kalimat menurunkan konsistensi di empat tugas, skala ordinal 1–5 jauh kurang stabil dibandingkan biner, dan ukuran parameter dalam satu keluarga model tidak menjamin stabilitas.	Pengujian 880 sampel berlabel manusia pada 25 *judge* (termasuk Qwen3) melalui selisih kesepakatan parafrase dan pengulangan (ΔJSS).	**Kelebihan:** Memisahkan pengaruh perubahan kalimat instruksi dari variasi dekoding bawaan. **Kekurangan:** Terbatas pada bahasa Inggris dan hanya menilai respons tunggal (*pointwise*) tanpa menguji pertukaran posisi kandidat.	Menguji perbandingan berpasangan (*pairwise*) Bahasa Indonesia IndoPref dengan tiga formulasi *prompt* setara semantik (P1, P2, P3) pada urutan posisi A–B dan B–A.
7	*The Coin Flip Judge? Reliability and Bias in LLM-as-a-Judge Evaluation* (2026) [16]	Penelitian ini menguji kestabilan putusan pada pasangan kandidat yang setara. Hasil pengulangan berbalik rata-rata 13,6%, GPT-4o-mini memilih posisi pertama pada 72% soal, muncul *pairwise–pointwise gap*, dan *template* setara semantik mengubah pemenang mayoritas pada 25% kasus.	Pengulangan 50 *trial* *pairwise* dan *pointwise* pada GPT-4o-mini serta GPT-4.1-mini di 29 soal, disertai pengujian $T = 0$ dan dua *template*.	**Kelebihan:** Menunjukkan ketidakkonsistenan pada kandidat setara yang tetap muncul pada $T = 0$. **Kekurangan:** Hanya menguji dua model OpenAI pada 29 soal bahasa Inggris tanpa label manusia.	Mengevaluasi 519 sampel Bahasa Indonesia berlabel penutur asli pada model *open-weight* dengan tiga formulasi *prompt* dan dua urutan posisi.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
8	*Reliability without Validity: A Systematic, Large-Scale Evaluation of LLM-as-a-Judge Models Across Agreement, Consistency, and Bias* (2026) [9]	Penelitian ini mengevaluasi 21 *judge* ($\sim$ 541.000 putusan) dan menemukan *kappa deflation* sebesar 33,8–41,3 poin persentase di MT-Bench serta *consistency–bias paradox* pada model dengan konsistensi pengulangan Krippendorff's $\alpha > 0,95$ yang tetap memiliki bias posisi tinggi.	Pengujian *agreement*, *consistency*, dan *bias audit* ($T = 0$) di MT-Bench, JudgeBench, serta RewardBench memakai *exact match*, Cohen's kappa, dan *flip rate*.	**Kelebihan:** Menunjukkan pentingnya penggunaan Cohen's kappa bersama pengujian posisi kandidat. **Kekurangan:** Hanya memakai satu *template* bahasa Inggris tanpa variasi formulasi *prompt*.	Menerapkan *accuracy*, Cohen's kappa, dan pengujian posisi pada Bahasa Indonesia sekaligus menguji tiga variasi formulasi *prompt*.
9	*How Reliable is Multilingual LLM-as-a-Judge?* (2025) [13]	Penelitian ini menguji konsistensi penilaian lintas 25 bahasa paralel (termasuk 142 sampel Bahasa Indonesia pada WikiLingua). Rata-rata konsistensi masih rendah (Fleiss' kappa $\approx 0,3$), format biner lebih stabil daripada skala 1–5, dan ukuran model tidak menjamin konsistensi.	Evaluasi *pointwise* (biner *Yes/No* dan skala 1–5) pada lima *judge* di lima dataset paralel memakai Fleiss' kappa, Cohen's kappa, dan *ensemble*.	**Kelebihan:** Mengukur ketidakkonsistenan lintas bahasa dan menunjukkan kestabilan format biner. **Kekurangan:** Hanya menguji skema *pointwise* dengan *prompt* bahasa Inggris tanpa pertukaran posisi.	Berfokus pada perbandingan *pairwise* dengan teks kandidat, *prompt*, dan preferensi manusia berbahasa Indonesia.

(Bersambung ke halaman berikutnya)

(Lanjutan Tabel 2.1)

No.	Judul dan Tahun	Pembahasan	Metode	Kelebihan dan Kekurangan	Perbedaan Penelitian
10	*IndoPref: A Multi-Domain Pairwise Preference Dataset for Indonesian* (2025) [14]	Penelitian ini membangun dataset preferensi berpasangan Bahasa Indonesia (522 *prompt*, 4.099 pasangan lintas 10 domain, Krippendorff's $\alpha = 0,891$) serta menguji 15 model. Akurasi tertinggi mencapai 74,34%, dan terjemahan *prompt* ke Bahasa Indonesia menurunkan akurasi GPT-4.1 sebesar 6,39 poin persentase.	Anotasi penutur asli dikonversi menjadi preferensi berpasangan, lalu diuji akurasinya pada satu urutan menggunakan 12 model *open-weight* dan 3 model tertutup.	**Kelebihan:** Menyediakan dataset *human preference* asli Bahasa Indonesia lintas 10 domain. **Kekurangan:** Hanya mengukur akurasi satu urutan tanpa pertukaran posisi A–B dan B–A, tanpa Cohen's kappa, serta tanpa variasi formulasi *prompt*.	Menggunakan IndoPref untuk menguji reliabilitas `Qwen/Qwen3-4B-Instruct-2507` pada pertukaran posisi (A–B dan B–A), tiga formulasi *prompt* setara semantik, dan Cohen's kappa.

Perbandingan penelitian pada Tabel 2.1 beserta literatur terkait menunjukkan bahwa evaluasi *LLM-as-a-Judge* tidak lagi cukup dilihat dari persentase kecocokan rata-rata, melainkan perlu memisahkan kesepakatan terhadap manusia dari konsistensi internal model. Penelitian awal melaporkan bahwa model penilai dapat mencapai kecocokan di atas 80% dengan manusia pada dialog terbuka [1], tetapi pengujian lintas 20 tugas pemrosesan bahasa alami menunjukkan tingkat kesepakatan yang sangat bervariasi antartugas [3], bahkan mendekati tebakan acak pada tugas verifikasi objektif ketika diuji dalam dua urutan posisi [17]. Dari sisi metrik evaluasi, persentase kecocokan mentah belum cukup menggambarkan kualitas penilai karena model dengan kecocokan rata-rata di atas 90% masih dapat berselisih lebih dari 10 poin persentase terhadap skor manusia [18]. Selain itu, nilai kecocokan mentah terbukti lebih tinggi 33,8–41,3 poin persentase dibandingkan Cohen's kappa pada MT-Bench (*kappa deflation*) karena belum memperhitungkan peluang acak [9], serta mudah berubah akibat perbedaan cara menangani abstensi, keluaran *invalid*, dan ketimpangan proporsi label [10]. Temuan bahwa tiga model *judge* yang bersepakat 100% tetap membalik 48,4% putusannya saat posisi ditukar [8], serta tingginya konsistensi pengulangan (Krippendorff's $\alpha = 0,992$ di MT-Bench) pada model yang memiliki bias posisi besar seperti Qwen 3 8B [9], turut menunjukkan adanya *consistency–bias paradox*, yaitu keluaran yang deterministik belum tentu bebas dari bias sistematis.

Hasil penelitian terdahulu juga menunjukkan bahwa arah *position bias* dan *prompt sensitivity* berbeda-beda antarmodel maupun antarpengaturan uji. Beberapa

penelitian menemukan kecenderungan kuat untuk memilih kandidat pertama (*primacy bias*), seperti 75,0% pada Claude-v1 [1] dan 72% kemenangan mayoritas posisi pertama pada GPT-4o-mini [16], sedangkan penelitian lain melaporkan kecenderungan ke kandidat kedua (*recency bias*), seperti lebih dari 78% kasus tidak konsisten pada GPT-4 dengan format Likert [15] serta perbedaan tanda nilai *preference fairness* antarmodel [5]. Ketidakkonsistenan akibat posisi ini semakin besar ketika kualitas kedua kandidat hampir setara [5][16]. Selain itu, bias posisi berkaitan erat dengan perumusan *prompt* karena pergantian *template* pada model yang sama dapat menggeser akurasi sekaligus membalik arah *position bias* [6]. Bahkan ketika instruksi ditulis ulang dengan makna yang setara secara semantik (*semantically equivalent*), konsistensi putusan tetap turun melebihi variasi dekoding bawaan [7] dan mengubah pemenang mayoritas pada 25% kasus [16], sementara ukuran parameter yang lebih besar dalam satu keluarga model tidak menjamin kestabilan keputusan terhadap perubahan kalimat *prompt* [7].

Meskipun berbagai sumber ketidakstabilan tersebut telah banyak diteliti, sebagian besar pengujian masih berfokus pada bahasa Inggris. Hanya 33 dari 650 publikasi *LLM-as-a-Judge* (5,1%) di ACL Anthology yang meneliti konteks multibahasa atau bahasa bersumber daya rendah, dan banyak di antaranya belum disertai validasi manusia yang memadai pada bahasa sasaran [12]. Padahal, pengujian lintas bahasa menunjukkan konsistensi penilaian yang rendah dengan rata-rata Fleiss' kappa sekitar 0,3 [13], berkurangnya selisih nilai menuju angka tengah pada bahasa bersumber daya rendah [19], perbedaan akurasi antarbahasa serta bias terhadap bahasa jawaban tertentu [20], dan meningkatnya ketidakkonsistenan posisi ketika bahasa pengujian bergeser dari bahasa Inggris [21]. Penelitian multibahasa yang menyertakan Bahasa Indonesia umumnya baru menggunakan data ringkasan WikiLingua dengan skema *pointwise* [13], data hasil terjemahan mesin [22], atau pasangan opsi soal pilihan ganda terjemahan MMMLU [20]. Sementara itu, pengujian pada dataset preferensi berpasangan Bahasa Indonesia IndoPref [14] baru mengukur akurasi pada satu urutan kandidat dan satu terjemahan *prompt* tanpa menguji pertukaran posisi kandidat maupun variasi formulasi *prompt*. Dengan demikian, literatur yang ada telah membuktikan keberadaan *position bias* dan *prompt sensitivity* pada *LLM-as-a-Judge*, tetapi penelitian khusus Bahasa Indonesia yang mengacu pada *human preference* serta menguji pengaruh posisi kandidat dan variasi formulasi *prompt* secara terpisah masih terbatas.

2.2. Landasan Teori

Bagian ini menguraikan konsep dan landasan teori yang mendasari pelaksanaan penelitian serta analisis pada bab-bab berikutnya. Pembahasan mencakup konsep *large language model* (LLM), paradigma *LLM-as-a-Judge*, ukuran reliabilitas model penilai, *position bias*, *prompt sensitivity*, evaluasi LLM pada Bahasa Indonesia, serta sintesis teori dan celah penelitian.

2.2.1. Large Language Models

Large language model (LLM) adalah model bahasa generatif berbasis jaringan saraf tiruan berskala besar yang memodelkan distribusi probabilitas kondisional atas barisan token secara autoregresif [2]. Melalui tahap prapelatihan pada korpus teks berukuran besar, model mempelajari pola bahasa dan pengetahuan lintas domain untuk memprediksi token berikutnya berdasarkan konteks masukan. Agar dapat mengikuti perintah pengguna dengan tepat, model dilatih lebih lanjut melalui penyelarasan instruksi (*instruction tuning*) dan preferensi manusia sehingga menghasilkan model *instruction-tuned* yang mampu memahami instruksi peran, kriteria penilaian, serta aturan format keluaran secara langsung pada saat inferensi [2][4].

Kemampuan tersebut memungkinkan pelaksanaan evaluasi berbasis inferensi (*inference-based evaluation*) dengan menggunakan bobot parameter model secara langsung tanpa pelatihan ulang atau *fine-tuning* [2][4]. Pada pendekatan ini, putusan model ditentukan oleh interaksi antara bobot hasil pelatihan, susunan konteks masukan, serta pengaturan dekoding seperti *temperature* dan batas maksimum token keluaran [7]. Salah satu model sumber terbuka (*open-weight*) yang mendukung pendekatan ini adalah `Qwen/Qwen3-4B-Instruct-2507`, yaitu model *instruction-tuned* berukuran 4 miliar parameter yang beroperasi dalam mode respons langsung tanpa tahapan penalaran internal (*non-thinking*) sehingga dapat langsung menghasilkan label keputusan secara ringkas. Dalam pelaksanaannya, inferensi model juga dapat dikombinasikan dengan teknik kuantisasi 4-bit untuk merepresentasikan bobot model secara lebih efisien dengan tetap mempertahankan kemampuan pemrosesan instruksinya.

2.2.2. LLM-as-a-Judge

LLM-as-a-Judge adalah metode evaluasi otomatis yang menggunakan LLM untuk menilai kualitas keluaran teks berdasarkan instruksi, kriteria, atau preferensi yang tertulis di dalam *prompt* [1][2]. Mengadaptasi formalisasi evaluasi berbasis LLM [2][4], apabila x menyatakan instruksi tugas awal, $\mathscr{R}$ menyatakan kandidat

respons yang dinilai, dan $\mathscr{C}$ menyatakan konteks *prompt* evaluasi, maka model memetakan seluruh masukan tersebut melalui distribusi probabilitas kondisional $\mathscr{P}_{\text{LLM}}$ dan fungsi ekstraksi keluaran $g(\cdot)$ menjadi putusan diskret $\hat{y} = g(\mathscr{P}_{\text{LLM}}(x, \mathscr{R}, \mathscr{C}))$.

Metode penilaian ini secara umum terbagi menjadi skema penilaian tunggal (*pointwise*) dan perbandingan berpasangan (*pairwise comparison*) [1][4]. Skema *pointwise* menilai setiap respons secara terpisah dalam bentuk skor angka, tetapi rentan terhadap ketidakkonsistenan skala nilai [15], berkurangnya selisih skor pada bahasa bersumber daya rendah [19], serta variasi nilai pada soal yang sama sehingga menyulitkan pembedaan dua kandidat yang kualitasnya hampir setara [1][4][16]. Sebaliknya, *pairwise comparison* membandingkan dua kandidat respons secara langsung untuk instruksi yang sama dan terbukti lebih selaras dengan preferensi manusia ketika perbedaan kualitas antarkandidat cukup tipis [1][4]. Pembatasan ruang putusan ke pilihan biner (`A` atau `B`) juga menghindari ketidakkonsistenan penentuan batas nilai antarkategori yang terbukti jauh lebih besar pada penilaian berskala ordinal 1–5 [7][13]. Namun, penyajian dua kandidat secara berurutan di dalam satu konteks membuat skema berpasangan rentan terhadap bias posisi [2] serta dapat memaksakan penentuan pemenang meskipun selisih skor kedua kandidat pada penilaian tunggal sangat kecil (*pairwise–pointwise gap*) [16].

2.2.3. Reliabilitas LLM Judge

Reliabilitas *LLM-as-a-Judge* mencakup dua aspek utama, yaitu kesepakatan keputusan model dengan preferensi manusia (*human agreement*) dan konsistensi keputusan internal ketika cara penyajiannya diubah tanpa mengubah isi kandidat [2][9]. Kedua aspek ini perlu diukur bersama karena model yang memberikan hasil tetap saat diuji berulang pada masukan identik masih dapat menyimpan bias sistematis yang menyimpang dari preferensi manusia [8][9], serta menggeser peringkat kualitas model apabila hasil penilaiannya digabungkan tanpa memperhitungkan keandalan penilai [11]. Oleh karena itu, reliabilitas dalam penelitian ini diukur melalui kesepakatan terhadap *human preference*, konsistensi posisi kandidat, dan konsistensi formulasi *prompt*.

Tingkat kesepakatan terhadap *reference human preference* pertama-tama diukur menggunakan proporsi kecocokan putusan valid (*accuracy*) pada Persamaan (2.1):

$$\text{Accuracy} = \frac{1}{N_{\text{valid}}} \sum_{i=1}^{N_{\text{valid}}} \mathbb{I}(\hat{y}_i = y_i) \tag{2.1}$$

dengan N_{valid} adalah jumlah putusan biner valid (`A` atau `B`), $\hat{y}_i \in \{\texttt{A}, \texttt{B}\}$ adalah putusan *judge*, $y_i \in \{\texttt{A}, \texttt{B}\}$ adalah label acuan manusia, dan $\mathbb{I}(\cdot)$ adalah fungsi indikator yang

bernilai 1 jika kondisi di dalamnya benar serta 0 jika salah. Karena *accuracy* belum memperhitungkan kesepakatan yang terjadi secara kebetulan [10][18] sehingga nilainya dapat jauh lebih tinggi daripada kesepakatan terkoreksi peluang (*kappa deflation*) [9], pengukurannya dilengkapi dengan Cohen's kappa (κ) [9][10] pada Persamaan (2.2):

$$\kappa = \frac{P_o - P_e}{1 - P_e} \tag{2.2}$$

dengan $P_o = \text{Accuracy}$ dan $P_e = P(y = \texttt{A})P(\hat{y} = \texttt{A}) + P(y = \texttt{B})P(\hat{y} = \texttt{B})$ sebagai peluang kesepakatan acak berdasarkan proporsi pilihan label manusia dan *judge*. Mengingat nilai *accuracy* maupun κ sangat dipengaruhi oleh cara penanganan keluaran yang gagal (*invalid*), keluaran model yang tidak menghasilkan label biner `A` atau `B` tidak dimasukkan ke salah satu kelas, melainkan dipisahkan dan dilaporkan persentasenya melalui *invalid rate* [10].

2.2.4. Position Bias

Position bias adalah kecenderungan sistematis model penilai untuk memilih salah satu kandidat berdasarkan urutan penempatannya di dalam *prompt*, terlepas dari isi respons yang dinilai [1][5]. Bias ini terjadi ketika pertukaran urutan penempatan kandidat mengubah putusan akhir ($\text{LLM}(x, R_\text{A}, R_\text{B}) \neq \text{LLM}(x, R_\text{B}, R_\text{A})$) [15], baik berupa kecenderungan memilih kandidat di urutan pertama (*primacy bias*) maupun di urutan kedua (*recency bias*) [5], dan semakin kuat ketika kualitas kedua kandidat hampir setara [4][5].

Pengujian *position bias* dilakukan melalui pertukaran urutan kandidat (*candidate swapping*) antara kondisi A–B (Respons A ditampilkan pertama, Respons B kedua) dan kondisi B–A (Respons B ditampilkan pertama, Respons A kedua) dengan tetap mempertahankan `A` serta `B` sebagai identitas kandidat [1][5][8]. Tanpa mengubah putusan yang berlawanan menjadi hasil seri (*tie*), pengaruh posisi kandidat diukur menggunakan *position consistency*, *preference flip rate*, dan *first-position preference rate* pada Persamaan (2.3)–(2.5) yang diadaptasi dari metrik evaluasi bias posisi [5][9][16]:

$$\text{Position Consistency} = \frac{1}{N_\text{pos}} \sum_{i=1}^{N_\text{pos}} \mathbb{I}\left(\hat{y}_{i,\text{AB}} = \hat{y}_{i,\text{BA}}\right) \tag{2.3}$$

$$\text{Preference Flip Rate} = \frac{1}{N_\text{pos}} \sum_{i=1}^{N_\text{pos}} \mathbb{I}\left(\hat{y}_{i,\text{AB}} \neq \hat{y}_{i,\text{BA}}\right) = 1 - \text{Position Consistency} \tag{2.4}$$

$$\text{First-Position Preference Rate} = \frac{1}{2N_{\text{pos}}} \sum_{i=1}^{N_{\text{pos}}} \left[\mathbb{I}\left(\hat{y}_{i,\text{AB}} = \texttt{A}\right) + \mathbb{I}\left(\hat{y}_{i,\text{BA}} = \texttt{B}\right) \right] \quad (2.5)$$

dengan N_{pos} menyatakan jumlah pasangan sampel yang memiliki putusan valid pada kedua urutan, serta $\hat{y}_{i,\text{AB}}, \hat{y}_{i,\text{BA}} \in \{\texttt{A}, \texttt{B}\}$ menyatakan identitas kandidat yang dipilih. Pada pengujian dua urutan yang seimbang, *first-position preference rate* digunakan untuk membedakan perubahan putusan yang bersifat acak dari kecenderungan sistematis untuk memilih kandidat di posisi pertama (nilai $> 0,50$) atau posisi kedua (nilai $< 0,50$).

2.2.5. Prompt Sensitivity

Prompt sensitivity adalah ketidakstabilan keputusan *LLM-as-a-Judge* akibat perubahan kalimat instruksi, rincian kriteria penilaian, atau aturan tambahan di dalam *prompt* meskipun tujuan evaluasi dan pasangan kandidat yang dinilai tetap sama [2][6][7]. Karena proses dekoding autoregresif bergantung pada susunan kata dan token di dalam konteks masukan, perbedaan struktur *template* maupun variasi kalimat yang setara secara semantik (*semantically equivalent*) tetap dapat menggeser fokus penilaian model serta mengubah arah bias posisinya [6][7].

Penyusunan *prompt* evaluasi terstruktur dengan komponen peran, konteks, tugas penilaian, dan format keluaran umumnya mencakup tiga pendekatan, yaitu perbandingan menyeluruh secara langsung (*baseline*) [1][2], perincian rubrik multi-kriteria seperti akurasi, relevansi, dan kejelasan untuk memperjelas dasar penilaian [2][4], serta penambahan aturan eksplisit anti-bias agar model mengabaikan urutan kandidat [1][8] dan panjang respons [1]. Penulisan alasan berantai (*Chain-of-Thought*) atau penjelasan sebelum putusan tidak digunakan pada pengujian utama agar keluaran model tetap berupa label biner, mengingat permintaan penjelasan bersamaan dengan putusan terbukti dapat menurunkan konsistensi posisi [2] serta penambahan instruksi penalaran bertahap dapat mengubah putusan mayoritas model [16]. Pada urutan posisi kandidat yang sama, konsistensi keputusan lintas tiga formulasi *prompt* (P1, P2, dan P3) diukur menggunakan *prompt consistency* serta *prompt flip rate* antarpasangan formulasi pada Persamaan (2.6) dan Persamaan (2.7) yang diadaptasi dari pengujian sensitivitas *prompt* [7][16]:

$$\text{Prompt Consistency} = \frac{1}{N_{\text{prompt}}} \sum_{i=1}^{N_{\text{prompt}}} \mathbb{I}\left(\hat{y}_{i,\text{P1}} = \hat{y}_{i,\text{P2}} = \hat{y}_{i,\text{P3}}\right) \quad (2.6)$$

$$\text{Prompt Flip Rate}_{(p,q)} = \frac{1}{N_{(p,q)}} \sum_{i=1}^{N_{(p,q)}} \mathbb{I}\left(\hat{y}_{i,p} \neq \hat{y}_{i,q}\right) \quad (2.7)$$

dengan N_{prompt} menyatakan jumlah sampel yang menghasilkan putusan valid pada ketiga formulasi dan $N_{(p,q)}$ menyatakan jumlah sampel valid pada pasangan $(p,q) \in \{(\text{P1},\text{P2}),(\text{P1},\text{P3}),(\text{P2},\text{P3})\}$. Perhitungan *flip rate* untuk setiap pasangan *prompt* ini digunakan untuk melihat perubahan formulasi mana yang paling banyak mengubah keputusan model.

2.2.6. Evaluasi LLM Bahasa Indonesia

Evaluasi otomatis pada teks Bahasa Indonesia masih menghadapi kendala karena terbatasnya porsi bahasa non-Inggris dalam data pelatihan LLM. Kondisi ini berdampak pada menyempitnya selisih skor penilaian pada bahasa bersumber daya rendah [19], rendahnya konsistensi putusan lintas bahasa [13], serta munculnya perbedaan performa antarbahasa dan bias terhadap bahasa jawaban tertentu [20]. Dataset evaluasi yang diterjemahkan dari bahasa Inggris juga sering kali kehilangan kealamian kalimat serta konteks budaya lokal [14], sedangkan penggunaan data terjemahan mesin dalam pelatihan penilai multibahasa terbukti menurunkan ketepatan model pada data pengujian berbahasa asli [22]. Di samping itu, penerjemahan instruksi *prompt* evaluasi ke Bahasa Indonesia terbukti dapat menurunkan akurasi penilai [14], sementara perubahan bahasa penyajian dari bahasa Inggris memicu pembalikan preferensi sebesar 10,7%–14,4% sekaligus meningkatkan ketidakkonsistenan posisi kandidat dari 12,1% menjadi 14,9%–18,1% [21].

Untuk menyediakan acuan evaluasi Bahasa Indonesia yang ditulis langsung oleh penutur asli, dataset IndoPref memuat 522 *prompt* lintas 10 domain (*Analysis*, *Brainstorming*, *Coding*, *Creative Writing*, *Logic*, *Math*, *Open Question*, *Safety*, *Summarization*, dan *Translation*) beserta 4.099 pasangan preferensi atas respons lima LLM *instruction-tuned* dengan tingkat kesepakatan antar-anotator Krippendorff's $\alpha = 0,891$ [14]. Dalam penelitian ini, label pada IndoPref digunakan sebagai *reference human preference* sesuai prosedur anotasinya, bukan sebagai kebenaran mutlak bagi seluruh penutur Bahasa Indonesia.

2.2.7. Sintesis dan Research Gap

Berdasarkan landasan teori yang telah diuraikan, ketika model *instruction-tuned* digunakan sebagai *pairwise LLM-as-a-Judge*, model memproses isi kedua kandidat sekaligus urutan penempatannya dan kalimat instruksi *prompt* dalam satu distribusi probabilitas kondisional [2][4]. Oleh karena itu, pengujian yang hanya melaporkan akurasi mentah pada satu urutan kandidat dan satu *prompt* belum cukup untuk menilai reliabilitas model. Nilai kecocokan mentah dapat meningkat akibat peluang acak dan ketimpangan proporsi label [10] sehingga memicu *kappa deflation*

[9], sedangkan putusan model tetap rentan berubah akibat *position bias* [5][8] dan *prompt sensitivity* [6][7], terutama pada evaluasi lintas bahasa dan Bahasa Indonesia yang sensitif terhadap perubahan bahasa penyajian maupun bahasa instruksi *prompt* [13][14][21].

Mengingat penelitian khusus Bahasa Indonesia berbasis *human preference* yang menguji pengaruh posisi kandidat dan variasi formulasi *prompt* secara terpisah masih terbatas, landasan teori tersebut digunakan sebagai dasar untuk menjawab rumusan masalah dan menguji hipotesis penelitian. Pertama, pengukuran kesepakatan yang memperhitungkan peluang acak digunakan untuk menilai tingkat konsistensi `Qwen/Qwen3-4B-Instruct-2507` terhadap *reference human preference* IndoPref melalui metrik *accuracy* dan Cohen's kappa. Kedua, pengujian pertukaran urutan kandidat (*candidate swapping*) digunakan untuk menguji hipotesis pertama mengenai pengaruh perubahan urutan A–B dan B–A melalui *position consistency*, *preference flip rate*, dan *first-position preference rate*. Ketiga, penggunaan tiga formulasi *prompt* yang setara secara semantik (*semantically equivalent*) digunakan untuk menguji hipotesis kedua mengenai pengaruh variasi *prompt* P1, P2, dan P3 melalui *prompt consistency* serta *prompt flip rate* berpasangan, yang tahapannya dijelaskan lebih lanjut pada Bab III.

BAB III

METODE PENELITIAN

Metode penelitian berisikan alur pembuatan model, dapat berupa diagram block proses atau flowchart, beserta penjelasannya.

3.1. Subjek dan Objek Penelitian

Berisi penjelasan terkait subjek atau objek yang akan diteliti. Rancangan sistem dapat berisikan rencana kebutuhan data (pengumpulan dan pre-processing data), serta skenario pengujian yang akan dilakukan.

3.2. Alat dan Bahan Penelitian

3.2.1. Alat Penelitian

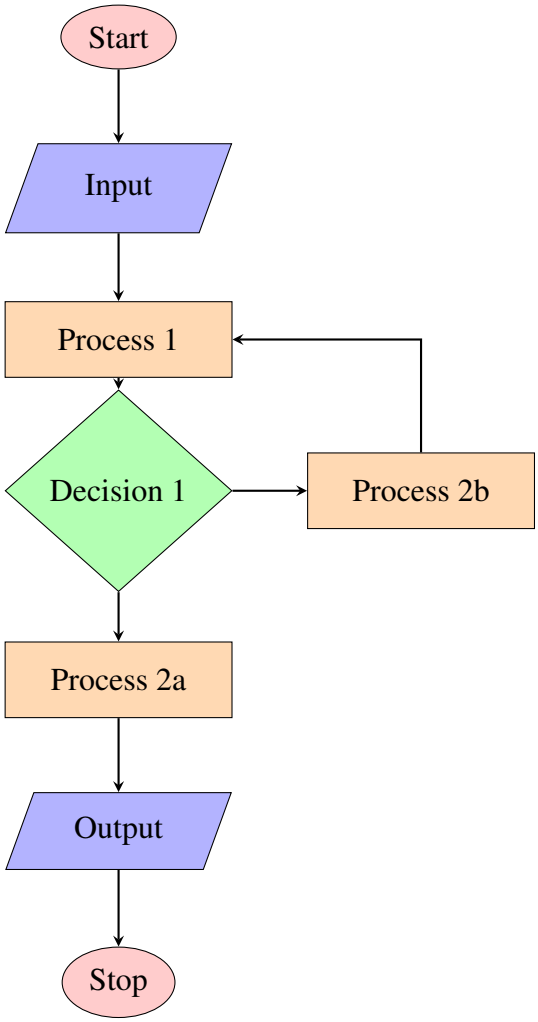
Sebutkan alat-alat (hardware/software) yang akan digunakan selama penelitian.

3.2.2. Bahan Penelitian

Sebutkan bahan-bahan pendukung, pustaka utama, atau dataset yang digunakan.

3.2.3. Diagram Alir Penelitian

Atau dalam bentuk algoritma seperti contoh pada Algoritma 1 berikut ini:



Gambar 3.1: Contoh Diagram Alir Penelitian

Algorithm 1 Prosedur simulasi algoritma.

```
1:  procedure FVDM(T final, Δt)
2:      Start
3:      For n = 1 : N do                          ▷ Pemberian nilai awal
4:          Input nilai x[n]
5:      EndFor
6:      time=0
7:      while time < T final do
8:              time = time + Δt
9:              If( S(n) ≤ 0m) then return End If.
10:                 OUTPUT Cetak hasil data.
11:     end while
12:     End
13: end procedure
```

BAB IV

HASIL DAN PEMBAHASAN

4.1. Hasil

Uraikan secara sistematis hasil penelitian atau pengujian yang telah dilakukan.

4.2. Pembahasan

Berikan analisis dan interpretasi mendalam terhadap hasil yang telah diperoleh, serta bandingkan dengan hipotesis atau teori yang ada.

4.3. Implikasi Tugas Akhir (Khusus SI)

(Khusus untuk mahasiswa Prodi S1 Sistem Informasi) Jelaskan implikasi dari hasil tugas akhir terhadap proses bisnis atau sistem yang berjalan.

BAB V

KESIMPULAN DAN SARAN

5.1. Kesimpulan

Berisi poin-poin kesimpulan yang menjawab rumusan masalah secara langsung.

5.2. Saran

Berisi masukan untuk pengembangan atau perbaikan penelitian selanjutnya berdasarkan keterbatasan penelitian ini.

DAFTAR PUSTAKA

[1] L. Zheng, W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica, "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," Dec. 2023.

[2] J. Gu, X. Jiang, Z. Shi, H. Tan, X. Zhai, C. Xu, W. Li, Y. Shen, S. Ma, H. Liu, S. Wang, K. Zhang, Y. Wang, W. Gao, L. Ni, and J. Guo, "A Survey on LLM-as-a-Judge," Oct. 2025.

[3] A. Bavaresco, R. Bernardi, L. Bertolazzi, D. Elliott, R. Fernández, A. Gatt, E. Ghaleb, M. Giulianelli, M. Hanna, A. Koller, A. F. T. Martins, P. Mondorf, V. Neplenbroek, S. Pezzelle, B. Plank, D. Schlangen, A. Suglia, A. K. Surikuchi, E. Takmaz, and A. Testoni, "LLMs instead of Human Judges? A Large Scale Empirical Study across 20 NLP Evaluation Tasks," June 2025.

[4] H. Li, Q. Dong, J. Chen, H. Su, Y. Zhou, Q. Ai, Z. Ye, and Y. Liu, "LLMs-as-Judges: A Comprehensive Survey on LLM-based Evaluation Methods," Dec. 2024.

[5] L. Shi, C. Ma, W. Liang, X. Diao, W. Ma, and S. Vosoughi, "Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge," in *Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics*, pp. 292–314, Association for Computational Linguistics, Dec. 2025.

[6] H. Wei, S. He, T. Xia, F. Liu, A. Wong, J. Lin, and M. Han, "Systematic Evaluation of LLM-as-a-Judge in LLM Alignment Tasks: Explainable Metrics and Diverse Prompt Templates," Mar. 2025.

[7] R. R. Bellibatlu, E. Raff, and W. Zhang, "JudgeSense: A Benchmark for Prompt Sensitivity in LLM-as-a-Judge Systems," Sept. 2026.

[8] C. Anghel, A. A. Anghel, E. Pecheanu, A. Cocu, A. Istrate, and C. A. Andrei, "Diagnosing Bias and Instability in LLM Evaluation: A Scalable Pairwise Meta-Evaluator," *Information*, vol. 16, p. 652, July 2025.

[9] J. D. Norman, M. U. Rivera, and D. A. Hughes, “Reliability without Validity: A Systematic, Large-Scale Evaluation of LLM-as-a-Judge Models Across Agreement, Consistency, and Bias,” June 2026.

[10] D. Rao and C. Callison-Burch, “Agreement Metrics for LLM-as-Judge Evaluation: What to Report and Why,” July 2026.

[11] M. Xu, X. Tan, J. Wu, and D. Zhou, “A Judge-Aware Ranking Framework for Evaluating Large Language Models without Ground Truth,” June 2026.

[12] A. S. Doğruöz, X. Liao, V. Blaschke, J. Prange, S. Li, and D. I. Adelani, “Challenges and Recommendations for LLM-as-a-Judge in Multilingual Settings and for Low-Resource Languages,” Sept. 2026.

[13] X. Fu and W. Liu, “How Reliable is Multilingual LLM-as-a-Judge?,” May 2025.

[14] V. R. Wiyono, D. Anugraha, A. Purwarianti, and G. I. Winata, “IndoPref: A Multi-Domain Pairwise Preference Dataset for Indonesian,” Nov. 2025.

[15] Z. Li, C. Wang, P. Ma, D. Wu, S. Wang, C. Gao, and Y. Liu, “Split and Merge: Aligning Position Biases in LLM-based Evaluators,” in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, (Miami, Florida, USA), pp. 11084–11108, Association for Computational Linguistics, 2024.

[16] A. Yagubyan, “The Coin Flip Judge? Reliability and Bias in LLM-as-a-Judge Evaluation,” Apr. 2026.

[17] S. Tan, S. Zhuang, K. Montgomery, W. Y. Tang, A. Cuadron, C. Wang, R. A. Popa, and I. Stoica, “JudgeBench: A Benchmark for Evaluating LLM-based Judges,” Apr. 2025.

[18] A. S. Thakur, K. Choudhary, V. S. Ramayapally, S. Vaidyanathan, and D. Hupkes, “Judging the Judges: Evaluating Alignment and Vulnerabilities in LLMs-as-Judges,” Aug. 2025.

[19] G. Son, D. Yoon, J. Suk, J. Aula-Blasco, M. Aslan, V. T. Kim, S. B. Islam, J. Prats-Cristià, L. Tormo-Bañuelos, and S. Kim, “MM-Eval: A Multilingual Meta-Evaluation Benchmark for LLM-as-a-Judge and Reward Models,” Mar. 2025.

[20] X. Zhou, Z. Luo, Y. Gao, Q. Chen, X. Hu, Y. Zhao, and R. Liu, “Fairness or Fluency? An Investigation into Language Bias of Pairwise LLM-as-a-Judge,” Jan. 2026.

[21] S. Yin, “Does the Judge Prefer English? Evaluating Language-Switching Invariance in LLM-as-a-Judge,” June 2026.

[22] J. Pombal, D. Yoon, P. Fernandes, I. Wu, S. Kim, R. Rei, G. Neubig, and A. F. T. Martins, “M-Prometheus: A Suite of Open Multilingual LLM Judges,” Oct. 2025.

Lampiran A: Daftar Pustaka dan Publikasi

Lampiran B: Source Code Program

Lampiran C: Panduan Penggunaan Aplikasi